

WYDZIAŁ MATEMATYKI I FIZYKI

STOSOWANEJ

Projekt: Wpływ kryzysu energetycznego na dynamikę przeładunków węgla i
koku w polskich portach morskich w latach 2010–2026: Statystyczna
analiza danych

Dominika Zięba

Rzeszów 2026

Spis treści

Wprowadzenie i metryka projektu.....	2
I. Opis użytych danych	2
II. Wyznaczenie podstawowych parametrów opisowych	5
III. Graficzna prezentacja danych.....	9
IV. Weryfikacja hipotez statystycznych.....	17
V. Komentarz do uzyskanych wyników	26
VI. Listing komend generujących wyniki	27
VII. Opis użytych funkcji środowiska R	30
Podsumowanie i wnioski końcowe	32

Wprowadzenie i metryka projektu

Niniejszy projekt stanowi kompleksową analizę statystyczną empirycznych danych makroekonomicznych dotyczących gospodarki morskiej Polski, ze szczególnym uwzględnieniem strategicznego surowca energetycznego, jakim jest **węgiel i koks**.

Projekt został przygotowany w środowisku **R** w ramach przedmiotu *Statystyczna analiza danych*.

I. Opis użytych danych

Źródło danych

Dane wykorzystane w niniejszym projekcie pochodzą z oficjalnych zasobów **Głównego Urzędu Statystycznego (GUS)**, publikowanych w ramach długich szeregów czasowych Biuletynu Statystycznego:

- **Baza danych:** GUS – Portal Informacyjny (*Biuletyn Statystyczny – Długie szeregi*)
- **Adres źródłowy:** <https://bazydanych.new.stat.gov.pl/biuletyn-statystyczny-dlugie-szeregi>
- **Nazwa tabeli GUS:** Tablica 53: Ładunki załadowane i wyładowane w portach morskich (tab153_ładunki_zaladowane_i_wyladowane_w_portach_morskich.xlsx)
- **Arkusz źródłowy:** Miesieczne_Monthly
- **Plik załącznika:** Do niniejszego projektu dołączono dedykowany arkusz kalkulacyjny dane_wegiel_koks_porty_2010_2026.xlsx (oraz format .csv), zawierający wyodrębnione i uporządkowane zmienne analityczne.

Czego dotyczą dane

Dane obejmują miesięczne obroty ładunkowe (sumę ładunków załadowanych i wyładowanych) w głównych polskich portach morskich o podstawowym znaczeniu dla gospodarki narodowej (Gdańsk, Gdynia, Szczecin, Świnoujście oraz Police) w latach **2010–2026** (od stycznia 2010 r. do lipca 2026 r. – łącznie $N = 199$ miesięcy obserwacji).

Zgodnie z metodologią GUS i dyrektywami unijnymi w zakresie statystyki transportu morskiego, waga ładunków podawana jest w **tysiącach ton** netto (bez wagi własnej jednostek ładunkowych, kontenerów i wagonów).

W analizie wyodrębniono następujące cechy:

1. `wegiel_koks_tys_ton` – miesięczny wolumen przeładunków węgla i koksu (w tys. ton) – **główna zmienna badawcza**,
2. `masowe_suche_tys_ton` – łączna masa ładunków masowych suchych (węgiel, koks, ruda, zboże, inne masowe) w tys. ton,

3. ogolem_tys_ton – całkowite obroty ładunkowe w portach morskich w danym miesiącu w tys. ton,
4. okres_badania – zmienna kategoryzująca szereg czasowy na dwa kluczowe podokresy:
 - **Okres 1 (2010–2021, $n_1 = 144$):** okres stabilny przed wybuchem wojny w Ukrainie,
 - **Okres 2 (2022–2026, $n_2 = 55$):** okres kryzysu energetycznego, embarga na rosyjski węgiel i skokowej reorientacji dostaw surowców drogą morską.

Uzasadnienie wyboru danych

Wybór węgla i koksu jako przedmiotu badania podyktowany jest jego kluczową rolą w polskim miksie elektroenergetycznym i ciepłownictwie oraz bezprecedensowymi wydarzeniami geopolitycznymi z 2022 roku.

Po wprowadzeniu embarga na węgiel z Federacji Rosyjskiej, Polska stanęła przed koniecznością natychmiastowego zastąpienia dostaw lądowych importem morskim z odległych kierunków (m.in. Kolumbia, RPA, Australia, Indonezja). Polskie porty morskie stały się strategicznym wąskim gardłem i osią bezpieczeństwa państwa. Analizowany zbiór danych pozwala w sposób empiryczny zweryfikować hipotezy dotyczące skali wstrząsu podażowego, dynamiki przetładunków oraz późniejszej stabilizacji rynku w latach 2024–2026.

```
# Dynamiczne wczytanie danych z arkusza kalkulacyjnego dołączonego do projektu
sciezka_dane <- "dane_wegiel_koks_porty_2010_2026.xlsx"

# Zabezpieczenie ścieżki w przypadku uruchamiania z różnego katalogu roboczego
if (!file.exists(sciezka_dane)) {
  sciezka_dane <- "src/chess-in-the-digital-age/dominika/dane_wegiel_koks_porty_2010_2026.xlsx"
}

dane <- as.data.frame(readxl::read_excel(sciezka_dane))
dane$data <- as.Date(dane$data)
dane$okres_badania <- factor(dane$okres_badania,
                             levels = c("2010-2021 (okres stabilny)",
                                           "2022-2026 (kryzys energetyczny)"))

# Podgląd struktury wczytanej próby
cat("Liczba zarejestrowanych miesięcy (N):", nrow(dane), "\n")

## Liczba zarejestrowanych miesięcy (N): 199

cat("Zakres chronologiczny:", as.character(min(dane$data)), "do",
    as.character(max(dane$data)), "\n")
```

Zakres chronologiczny: 2010-01-01 do 2026-07-01

II. Wyznaczenie podstawowych parametrów opisowych

W celu empirycznego scharakteryzowania rozkładu miesięcznych przeładunków węgla i koksu (wegiel_koks_tys_ton) wyznaczono zestaw podstawowych parametrów opisowych obejmujących miary położenia, rozproszenia, asymetrii i koncentracji.

Kod obliczeniowy w środowisku R

```
# Wektor analizowanej cechy
x <- dane$wegiel_koks_tys_ton

# 1. Średnia arytmetyczna
sr_arytm <- mean(x)

# 2. Odchylenie standardowe
odch_std <- sd(x)

# 3. Wariancja
wariancja <- var(x)

# 4. Klasyczny współczynnik zmienności (procentowy)
wsp_zmienosci <- (odch_std / sr_arytm) * 100

# 5. Odchylenie przeciętne / medianowe (MAD)
odch_przecietne <- mad(x, center = median(x))

# 6. Współczynnik asymetrii (skośność)
skosnosc <- moments::skewness(x)

# 7. Współczynnik koncentracji (kurtoza)
kurtoza <- moments::kurtosis(x)

# 8. Estymowana moda (dominanta wyznaczona z jądrowego estymatora gęstości)
gestosc <- density(x)
moda_est <- gestosc$x[which.max(gestosc$y)]

# 9. Pozycyjne miary kwantylowe
q_min <- min(x)
q_q1 <- as.numeric(quantile(x, 0.25))
q_med <- median(x)
q_q3 <- as.numeric(quantile(x, 0.75))
q_max <- max(x)
rozstep <- q_max - q_min
iqr_val <- IQR(x)

# 10. Pozycyjny współczynnik zmienności (oparty na odchyleniu ćwiartkowym i medianie)
vq_pozycyjny <- ((iqr_val / 2) / q_med) * 100
```

Zestawienie tabelaryczne parametrów

Tabela 1. Podstawowe parametry opisowe przeładunków węgla i koksu w polskich portach morskich (2010–2026)

Lp	Parametr	Symbol	Wartość	Typ miary
1	Średnia arytmetyczna	$\bar{x}$	942.62 tys. t	Klasyczna położenia
2	Odchylenie standardowe	s	460.65 tys. t	Klasyczna zróżnicowania
3	Wariancja	s^2	212196.76 (tys. t) ²	Klasyczna zróżnicowania
4	Klasyczny współczynnik zmienności	V	48.87 %	Klasyczna zmienności względnej
5	Odchylenie przeciętne medianowe (MAD)	MAD	229.06 tys. t	Pozycyjna zróżnicowania
6	Współczynnik asymetrii (skośność)	γ_1	2.8740	Klasyczna asymetrii
7	Współczynnik skupienia (kurtoza)	β_2	13.3692	Klasyczna koncentracji
8	Estymowana moda (dominanta)	Mo	782.17 tys. t	Pozycyjna położenia
9	Kwantyle (Min, Q1, Me, Q3, Max, IQR, R)	$Q_{0..4}, IQR$	Min=280.2; Me=857.6; Max=3449.8 (IQR=311.2)	Zestaw miar pozycyjnych
10	Pozycyjny współczynnik zmienności	V_Q	18.15 %	Pozycyjna zmienności względnej

Szczegółowa interpretacja wyznaczonych parametrów opisowych

- Średnia arytmetyczna (942.62 tys. ton):** Przeciętny miesięczny wolumen przeładunków węgla i koksu w polskich portach morskich w latach 2010–2026 wynosił około 942,6 tys. ton. Wartość ta reprezentuje teoretyczny środek ciężkości rozkładu.
- Odchylenie standardowe (460.65 tys. ton):** Miesięczne przeładunki węgla i koksu odchylają się przeciętnie od średniej arytmetycznej aż o 460,6 tys. ton. Wskazuje to na znaczne wahania wolumenu obrotów pomiędzy poszczególnymi miesiącami.
- Wariancja (212196.76):** Bardzo wysoka wartość wariancji potwierdza dużą zmienność zjawiska w czasie, wywołaną zarówno cyklem koniunkturalnym, jak i nagłym szokiem importowym po 2022 roku.

4. **Klasyczny współczynnik zmienności (48.87%):** Wartość współczynnika zmienności na poziomie ok. 48,9% mieści się w przedziale dużej zmienności (w statystyce przedział 40–70% oznacza dużą dyspersję). Oznacza to, że przeładunki węgla w portach morskich nie są stabilne w czasie i charakteryzują się wysoką nieregularnością.
5. **Odchylenie przeciętne / medianowe MAD (229.06 tys. ton):** Mediana bezwzględnych odchyłeń od mediany wynosi 229,1 tys. ton. Ponieważ MAD jest odporny na wartości ekstremalne, jest wyraźnie niższy od odchylenia standardowego, co potwierdza obecność silnych wartości odstających w zbiorze danych.
6. **Skośność (2.8740):** Dodatnia wartość współczynnika asymetrii ($\gamma_1 > 0$) świadczy o **silnej asymetrii prawostronnej (prawostronnym wydłużeniu ogona rozkładu)**. W większości miesięcy obroty węglem kształtowały się na umiarkowanym poziomie, a nieliczne miesiące o skrajnie wysokich przeładunkach (szczyt kryzysu energetycznego w 2022/2023 r.) spowodowały wydłużenie prawego ogona.
7. **Kurtoza (13.3692):** Wartość kurtozy wynosząca 13,37 znacznie przekracza wartość referencyjną dla rozkładu normalnego ($\beta_2 = 3$). Świadczy to o **rozkładzie wybitnie leptokurtycznym** – cechuje go wysokie skupienie wartości wokół dominanty oraz „grube ogony”, czyli znacznie większe prawdopodobieństwo wystąpienia wartości skrajnych niż w rozkładzie Gaussa.
8. **Estymowana moda (782.17 tys. ton):** Najczęściej powtarzający się (typowy) poziom miesięcznych przeładunków wynosi około 782,2 tys. ton. Fakt, że $Mo < Me < \bar{x}$ ($782,2 < 857,6 < 942,6$), jest klasycznym potwierdzeniem prawostronnej asymetrii rozkładu.
9. **Kwantyle:**
 - **Minimum (280.2 tys. ton):** Najniższy zarejestrowany miesięczny przeładunek węgla i koksu (odnotowany w maju 2020 r. w okresie pandemii COVID-19 i załamania przemysłu).
 - **Pierwszy kwartyl Q_1 (710.4 tys. ton):** W 25% analizowanych miesięcy przeładunki węgla i koksu nie przekraczały 710,4 tys. ton.
 - **Mediana Me (857.6 tys. ton):** W połowie badanych miesięcy obroty węglem były niższe niż 857,6 tys. ton, a w drugiej połowie – wyższe.
 - **Trzeci kwartyl Q_3 (1021.6 tys. ton):** W 75% badanych miesięcy przeładunki były niższe niż 1021,6 tys. ton (lub równoważnie: w 25% miesięcy przekroczyły ten poziom).
 - **Maksimum (3449.8 tys. ton):** Absolutny rekord przeładunków (ponad 3,44 mln ton w ciągu jednego miesiąca!) odnotowano w grudniu 2022 roku, w kulminacyjnym momencie interwencyjnego importu węgla po odcięciu dostaw ze Wschodu.

- **Rozstęp całkowity R (3169.6 tys. ton):** Różnica między skrajnymi wartościami wynosi aż 3,17 mln ton, ukazując potężną skalę wahań operacyjnych w polskich portach.
 - **Rozstęp ćwiartkowy IQR (311.2 tys. ton):** Środkowe 50% obserwacji mieści się w relatywnie wąskim przedziale o szerokości 311,3 tys. ton.
10. **Pozycyjny współczynnik zmienności (18.15%):** Relacja połowy rozstępu ćwiartkowego do mediany wynosi 18,15%. Wartość ta jest ponad dwukrotnie niższa od klasycznego współczynnika zmienności (48,87%), co jednoznacznie dowodzi, że zasadniczy zręb danych jest stabilny, a wysoka zmienność klasyczna wynikała z ekstremalnych anomalii kryzysowych z lat 2022–2023.

III. Graficzna prezentacja danych


W niniejszym rozdziale przedstawiono graficzną analizę rozkładu oraz dynamiki przeładunków węgla i koksu w czasie, przygotowaną przy użyciu pakietu ggplot2.

Typ 1: Histogram z nałożoną krzywą gęstości empirycznej

```
ggplot(dane, aes(x = wegciel_koks_tys_ton)) +  
  geom_histogram(aes(y = after_stat(density)), bins = 25,  
                 fill = "#2c3e50", color = "white", alpha = 0.85) +  
  geom_density(color = "#e74c3c", linewidth = 1.1) +  
  stat_function(fun = dnorm,  
               args = list(mean = mean(dane$wegciel_koks_tys_ton),  
                           sd = sd(dane$wegciel_koks_tys_ton)),  
               color = "#3498db", linetype = "dashed", linewidth = 0.9) +  
  geom_vline(aes(xintercept = mean(wegciel_koks_tys_ton)),  
             color = "#27ae60", linewidth = 0.9, linetype = "dashed") +  
  geom_vline(aes(xintercept = median(wegciel_koks_tys_ton)),  
             color = "#f39c12", linewidth = 0.9, linetype = "dotted") +  
  labs(  
    title = "Rysunek 1. Histogram przeładunków węgla i koksu",  
    subtitle = "Rozkład empiryczny na tle teoretycznego rozkładu normalnego",  
    x = "Przeładunki węgla i koksu (tys. ton)",  
    y = "Gęstość prawdopodobieństwa"  
  ) +  
  theme_minimal(base_size = 10) +  
  theme(  
    plot.title = element_text(size = 10, face = "bold", hjust = 0),  
    plot.subtitle = element_text(size = 8.5, color = "#444444"),  
    plot.margin = margin(t = 10, r = 25, b = 10, l = 10)  
  )
```

Rysunek 1. Histogram przeładunków węgla i koksu


Rozkład empiryczny na tle teoretycznego rozkładu normalnego



Komentarz do wykresu 1: Histogram jednoznacznie ilustruje skośność prawostronną. Większość obserwacji skupia się w przedziale 600–1100 tys. ton. Po prawej stronie widoczny jest wydłużony ogon sięgający wartości powyżej 3000 tys. ton. Rozkład empiryczny (linia czerwona) wyraźnie odbiega od symetrycznego rozkładu Gaussa (linia niebieska), co zapowiada odrzucenie hipotezy o normalności rozkładu.

Typ 2: Wykres pudełkowy (Boxplot) z podziałem na okresy


```
ggplot(dane, aes(x = okres_badania, y = wegciel_koks_tys_ton, fill =  
okres_badania)) +  
  geom_boxplot(alpha = 0.75, outlier.color = "#c0392b", outlier.size = 2.5,  
outlier.shape = 19) +  
  stat_summary(fun = mean, geom = "point", shape = 18, size = 4, color =  
"black") +  
  scale_fill_manual(values = c("#2980b9", "#d35400")) +  
  labs(  
    title = "Rysunek 2. Wykres pudełkowy przeładunków węgla i koksu",  
    subtitle = "Porównanie rozkładów w podziale na okres stabilny i  
kryzysowy",  
    x = "Okres analizy",  
    y = "Przeładunki węgla i koksu (tys. ton)"  
  ) +  
  theme_minimal(base_size = 10) +  
  theme(  
    plot.title = element_text(size = 10, face = "bold", hjust = 0),  
    plot.subtitle = element_text(size = 8.5, color = "#444444"),  
    plot.margin = margin(t = 10, r = 25, b = 10, l = 10),  
    legend.position = "none"  
  )  
)
```



Komentarz do wykresu 2: Wykres pudełkowy uwypukla kolosalną zmianę strukturalną. W okresie 2010–2021 rozstęp międzykwartyłowy był zwarty, a mediana wynosiła około 830 tys. ton. Z kolei po 2022 roku zarówno „pudełko” (IQR), jak i rozpiętość wąsów gwałtownie wzrosły, a w okresie kryzysowym wystąpiła seria wyraźnych wartości odstających (*outliers*) przekraczających 2500–3400 tys. ton. Średnia (romb) w okresie kryzysowym leży znacznie powyżej mediany.

Typ 3: Dystrybuanta empiryczna (ECDF)


```
ggplot(dane, aes(x = wegciel_koks_tys_ton, color = okres_badania)) +  
  stat_ecdf(geom = "step", linewidth = 1.1) +  
  scale_color_manual(values = c("#2980b9", "#d35400")) +  
  labs(  
    title = "Rysunek 3. Dystrybuanta empiryczna (ECDF) przeładunków",  
    subtitle = "Porównanie funkcji prawdopodobieństwa  $P(X \leq x)$  dla obu  
okresów",  
    x = "Przeładunki węgla i koksu (tys. ton)",  
    y = "Dystrybuanta empiryczna  $F_n(x)$ ",  
    color = "Podokres"  
  ) +  
  theme_minimal(base_size = 10) +  
  theme(  
    plot.title = element_text(size = 10, face = "bold", hjust = 0),  
    plot.subtitle = element_text(size = 8.5, color = "#444444"),  
    plot.margin = margin(t = 10, r = 25, b = 10, l = 10),  
    legend.position = "bottom"  
  )  
)
```



Komentarz do wykresu 3: Przesunięcie krzywej dystrybuanty dla okresu 2022–2026 (kolor pomarańczowy) w prawo względem krzywej z lat 2010–2021 (kolor niebieski) oznacza stochastyczną dominację. Dla każdego ustalonego progu wolumenu przeładunków x , prawdopodobieństwo nieprzekroczenia tej wartości w okresie kryzysowym było znacznie mniejsze niż w okresie stabilnym, co dowodzi uogólnionego przesunięcia całego rozkładu w stronę wyższych wartości.

Typ 4: Szereg czasowy z wykładaniem trendu (Time Series Plot)


```
ggplot(dane, aes(x = data, y = weg_iel_koks_tys_ton)) +  
  geom_line(color = "#34495e", linewidth = 0.7) +  
  geom_point(aes(color = okres_badania), size = 1.5, alpha = 0.8) +  
  geom_smooth(method = "loess", color = "#e74c3c", fill = "#f5b7b1", alpha =  
0.35, linewidth = 1.0) +  
  geom_vline(xintercept = as.numeric(as.Date("2022-02-24")),  
            linetype = "dashed", color = "#c0392b", linewidth = 0.9) +  
  annotate("text", x = as.Date("2021-11-01"), y = 3200,  
         label = "Inwazja na Ukrainę\ni embargo węglowe",  
         hjust = 1, color = "#c0392b", size = 3.1, fontface = "bold") +  
  scale_color_manual(values = c("#2980b9", "#d35400")) +  
  labs(  
    title = "Rysunek 4. Miesięczne przeładunki węgla i koksu (2010–2026)",  
    subtitle = "Dane miesięczne GUS oraz trend nieliniowy wygładzony metodą  
LOESS",  
    x = "Rok",  
    y = "Przeładunki węgla i koksu (tys. ton)",  
    color = "Okres"  
  ) +  
  theme_minimal(base_size = 10) +  
  theme(  
    plot.title = element_text(size = 10, face = "bold", hjust = 0),  
    plot.subtitle = element_text(size = 8.5, color = "#444444"),  
    plot.margin = margin(t = 10, r = 25, b = 10, l = 10),  
    legend.position = "bottom"  
  )  
)
```



Komentarz do wykresu 4: Szereg czasowy w pełnej krasie ukazuje stabilny, lekko rosnący przebieg przeładunków w latach 2010–2021 z widocznymi cyklami sezonowymi (wyższe przeładunki przed i w trakcie sezonu grzewczego). W 2022 roku po wybuchu wojny nastąpił bezprecedensowy skok wolumenów do poziomów 3–3,5 mln ton miesięcznie. Następnie w latach 2024–2026 widoczny jest wyraźny powrót w kierunku poziomów równowagi rynkowej (normalizacja zapasów).

Typ 5: Wykres korelacji rozrzutu z dopasowaną prostą regresji

```
ggplot(dane, aes(x = masowe_suche_tys_ton, y = weg_iel_koks_tys_ton)) +  
  geom_point(aes(color = okres_badania), size = 1.9, alpha = 0.75) +  
  geom_smooth(method = "lm", color = "#2c3e50", fill = "#bdc3c7", linewidth =  
1.0) +  
  scale_color_manual(values = c("#2980b9", "#d35400")) +  
  labs(  
    title = "Rysunek 5. Przeładunki węgla a ładunki masowe suche",  
    subtitle = "Wykres rozrzutu z dopasowaną prostą regresji liniowej OLS",  
    x = "Ładunki masowe suche ogółem w portach (tys. ton)",  
    y = "Przeładunki węgla i koksu (tys. ton)",  
    color = "Okres"  
  ) +  
  theme_minimal(base_size = 10) +  
  theme(  
    plot.title = element_text(size = 10, face = "bold", hjust = 0),  
    plot.subtitle = element_text(size = 8.5, color = "#444444"),  
    plot.margin = margin(t = 10, r = 25, b = 10, l = 10),  
    legend.position = "bottom"  
  )  
)
```



Komentarz do wykresu 5: Wykres rozrzutu ukazuje bardzo wyraźną współbieżność liniową pomiędzy wolumenem węgla i koksu a łączną masą ładunków suchych przeładowywanych w polskich portach. Punkty z okresu kryzysowego (pomarańczowe) przesunęły się w prawy górny róg wykresu, odzwierciedlając skok obu miar w tym samym czasie.

IV. Weryfikacja hipotez statystycznych

W niniejszym rozdziale przeprowadzono weryfikację hipotez statystycznych dotyczących zależności między cechami oraz istotności różnic między badanymi podokresami.

Wszystkie testy zrealizowano na standardowym poziomie istotności $\alpha = 0,05$.

Weryfikacja wstępna: Test normalności rozkładu Shapiro-Wilka

Przed przystąpieniem do testów parametrycznych sprawdzono założenie o zgodności rozkładów analizowanych cech z rozkładem normalnym.

- **Hipoteza zerowa (H_0):** Rozkład badanej cechy jest rozkładem normalnym.
- **Hipoteza alternatywna (H_1):** Rozkład badanej cechy różni się istotnie od rozkładu normalnego.

```
shapiro_wegiel <- shapiro.test(dane$wegiel_koks_tys_ton)
shapiro_masowe <- shapiro.test(dane$masowe_suche_tys_ton)

wyniki_shapiro <- data.frame(
  Zmienna = c("Węgiel i koks", "Ładunki masowe suche"),
  Statystyka_W = sprintf("%.4f", c(shapiro_wegiel$statistic,
shapiro_masowe$statistic)),
  p_value = sprintf("%.4e", c(shapiro_wegiel$p.value,
shapiro_masowe$p.value)),
  Decyzja = c("Odrzucenie H0 (p < 0.05)", "Odrzucenie H0 (p < 0.05)"),
  Wniosek = c("Rozkład nie jest normalny", "Rozkład nie jest normalny")
)
colnames(wyniki_shapiro) <- c("Zmienna", "Statystyka W", "p-value", "Decyzja
(alpha = 0.05)", "Wniosek")

knitr::kable(wyniki_shapiro, caption = "Tabela 2. Wyniki testu normalności
Shapiro-Wilka")
```

Tabela 2. Wyniki testu normalności Shapiro-Wilka

Zmienna	Statystyka		Decyzja (alpha = 0.05)	Wniosek
	W	p-value		
Węgiel i koks	0.7156	3.6258e-18	Odrzucenie H0 (p < 0.05)	Rozkład nie jest normalny
Ładunki masowe suche	0.8309	6.0782e-14	Odrzucenie H0 (p < 0.05)	Rozkład nie jest normalny

Interpretacja: Dla obu zmiennych wartość p -value $\ll 0,05$ (dla węgla $p \approx 3,63 \times 10^{-18}$). Odrzucamy hipotezę zerową na korzyść hipotezy alternatywnej. Oznacza to, że dane cechują się istotnym odchyleniem od rozkładu normalnego (asymetria prawostronna i

leptokurtoza). W związku z tym w dalszych badaniach korelacji przedstawiono zarówno współczynnik Pearsona, jak i nieparametryczny współczynnik Spearmana.

Hipoteza 1: Test korelacji (zależności między cechami)

W pierwszej hipotezie badamy, czy istnieje statystycznie istotna korelacja liniowa między wolumenem przeładunków węgla i koksu a ogólną sumą ładunków masowych suchych obsługiwanych w portach.

- **Hipoteza zerowa (H_0):** $\rho = 0$ – nie istnieje statystycznie istotna korelacja między przeładunkiem węgla i koksu a przeładunkiem ładunków masowych suchych.
- **Hipoteza alternatywna (H_1):** $\rho \neq 0$ – istnieje statystycznie istotna korelacja między przeładunkiem węgla i koksu a przeładunkiem ładunków masowych suchych.

```
# Test korelacji liniowej Pearsona
test_pearson <- cor.test(dane$wegiel_koks_tys_ton, dane$masowe_suche_tys_ton,
method = "pearson")

# Test korelacji rangowej Spearmana (odporny na brak normalności)
test_spearman <- cor.test(dane$wegiel_koks_tys_ton,
dane$masowe_suche_tys_ton, method = "spearman", exact = FALSE)

wyniki_korelacji <- data.frame(
  Metoda = c("Korelacja liniowa Pearsona (r)", "Korelacja rangowa Spearmana (rho)"),
  Wspolczynnik = sprintf("%.4f", c(test_pearson$estimate,
test_spearman$estimate)),
  Statystyka = sprintf("%.2f", c(test_pearson$statistic,
test_spearman$statistic)),
  p_value = c("< 2.2e-16", "< 2.2e-16"),
  Przedzial_Ufnosci_95 = c(
    sprintf("[%.4f ; %.4f]", test_pearson$conf.int[1],
test_pearson$conf.int[2]),
    "nie dotyczy"
  )
)
colnames(wyniki_korelacji) <- c("Metoda korelacji", "Współczynnik",
"Statystyka testowa", "p-value", "95% Przedział ufności")

knitr::kable(wyniki_korelacji, caption = "Tabela 3. Wyniki testu istotności
współczynników korelacji")
```

Tabela 3. Wyniki testu istotności współczynników korelacji

Metoda korelacji	Współczy nnik	Statystyka testowa	p- value	95% Przedział ufności
Korelacja liniowa Pearsona (r)	0.8630	23.97	< 2.2e- 16	[0.8226 ; 0.8947]
Korelacja rangowa Spearmana (rho)	0.6149	505744.39	< 2.2e- 16	nie dotyczy

Interpretacja i decyzja statystyczna:

- Współczynnik korelacji Pearsona wynosi $r = 0.8630$, a statystyka testowa $t = 23.97$ przy $p\text{-value} < 2,2 \times 10^{-16}$.
- Ponieważ uzyskana wartość $p\text{-value} < 0,05$, **odrzucaamy hipotezę zerową (H_0) na rzecz hipotezy alternatywnej (H_1)**.
- **Wniosek:** Istnieje statystycznie istotna, bardzo silna dodatnia korelacja liniowa między przeładunkami węgla i koksu a ogólnymi przeładunkami ładunków masowych suchych. Potwierdza to, że węgiel i koks stanowią fundamentalną składową determinującą całkowity wolumen suchej masy przeładowywanej na nabrzeżach polskich portów morskich.

Hipoteza 2: Porównanie dwóch populacji (okres stabilny vs okres kryzysu)

W drugiej hipotezie badamy wpływ wstrząsu geopolitycznego z 2022 roku na poziom przetadunków węgla i koksu. Porównujemy dwa niezależne podzbiory czasowe:

- **Próba A (okres 2010–2021, $n_A = 144$):** wielkości przetadunków przed kryzysem,
- **Próba B (okres 2022–2026, $n_B = 55$):** wielkości przetadunków w trakcie kryzysu surowcowego i reorientacji dostaw.

Krok 1: Test równości wariancji Fishera-Snedecora (`var.test`)

Przed wykonaniem testu t-Studenta sprawdzono jednorodność wariancji w obu podokresach:

- $H_0: \sigma_A^2 = \sigma_B^2$ (wariancje w obu okresach są równe),
- $H_1: \sigma_A^2 \neq \sigma_B^2$ (wariancje w obu okresach różnią się istotnie).

```
probka_A <- dane$wegiel_koks_tys_ton[dane$okres_badiania == "2010-2021 (okres stabilny)"]
probka_B <- dane$wegiel_koks_tys_ton[dane$okres_badiania == "2022-2026 (kryzys energetyczny)"]
```

```
test_var <- var.test(probka_A, probka_B)
cat("Statystyka F:", sprintf("%.4f", test_var$statistic), "p-value:",
    sprintf("%.4e", test_var$p.value), "\n")
```

```
## Statystyka F: 0.0956 p-value: 4.4035e-29
```

Wartość $p\text{-value} \ll 0,05$. Odrzucamy hipotezę zerową o jednorodności wariancji. Z tego względu zastosowano **dwupróbowy test t-Studenta z korektą Welcha** dla wariancji niejednorodnych.

Krok 2: Dwupróbowy test t-Studenta dla prób niezależnych (`t.test`)

- **Hipoteza zerowa (H_0):** $\mu_A - \mu_B = 0$ (średnie miesięczne przetadunki węgla i koksu w okresie stabilnym 2010–2021 oraz w okresie kryzysowym 2022–2026 **nie różnią się statystycznie istotnie**).
- **Hipoteza alternatywna (H_1):** $\mu_A - \mu_B \neq 0$ (średnie miesięczne przetadunki węgla i koksu w obu analizowanych okresach **różnią się statystycznie istotnie** – wystąpił istotny wpływ kryzysu).

```
test_t <- t.test(probka_A, probka_B, alternative = "two.sided", var.equal = FALSE)
```

```
tabela_test_t <- data.frame(
  Okres = c("2010-2021 (przed kryzysem)", "2022-2026 (po kryzysie)", "Różnica (A - B)"),
  n = c(as.character(length(probka_A)), as.character(length(probka_B)), "-"),
```

```

Srednia = c(
  sprintf("%.2f tys. t", mean(probka_A)),
  sprintf("%.2f tys. t", mean(probka_B)),
  sprintf("%.2f tys. t", mean(probka_A) - mean(probka_B))
),
Odch_Std = c(
  sprintf("%.2f tys. t", sd(probka_A)),
  sprintf("%.2f tys. t", sd(probka_B)),
  "-"
),
t = c("-", "-", sprintf("%.4f", test_t$statistic)),
df = c("-", "-", sprintf("%.2f", test_t$parameter)),
p_val = c("-", "-", sprintf("%.6f", test_t$p.value)),
CI_95 = c(
  "-", "-",
  sprintf("[%.2f ; %.2f]", test_t$conf.int[1], test_t$conf.int[2])
)
)
colnames(tabela_test_t) <- c("Okres", "n", "Średnia", "Odch. std.",
"Statystyka t", "df", "p-value", "95% CI dla różnicy")

knitr::kable(tabela_test_t, caption = "Tabela 4. Wyniki dwupróbowego testu t-
Studenta dla średnich miesięcznych przeładunków")

```

Tabela 4. Wyniki dwupróbowego testu t-Studenta dla średnich miesięcznych przeładunków

Okres	n	Średnia	Odch. std.	Statystyka t	df	p-value	95% CI dla różnicy
2010–2021 (przed kryzysem)	1	836.92	226.12	-	-	-	-
	4	tys. t	tys. t				
	4						
2022–2026 (po kryzysie)	5	1219.36	731.34	-	-	-	-
	5	tys. t	tys. t				
Różnica (A - B)	-	-382.44	-	-3.8093	57	0.000	[-583.41 ; -
		tys. t			.9	339	181.47]
					9		

Interpretacja i decyzja statystyczna:

- Średnia miesięczna przed 2022 r. wynosiła 836,92 tys. ton, natomiast po wybuchu kryzysu wzrosła do 1219,36 tys. ton (wzrost średnich obrotów o ponad 382,44 tys. ton miesięcznie!).
- Statystyka testowa wynosi $t = -3.8093$ przy $df \approx 58$ stopniach swobody oraz wartości $p\text{-value} = 0.000339 < 0,05$.
- **Decyzja:** Odrzucamy hipotezę zerową (H_0) na rzecz hipotezy alternatywnej (H_1).
- **Wniosek:** Istnieje statystycznie istotna różnica między średnimi miesięcznymi przeładunkami węgla i koksu w okresie 2010–2021 a okresem 2022–2026. Z 95%

pewnością różnica średnich mieści się w przedziale $[-583,41; -181,47]$ tys. ton. Kryzys geopolityczny i embargo radykalnie i trwale wpłynęły na przeciętny poziom obrotów w portach morskich.

Rozszerzenie: Porównanie nachyleń trendów liniowych przed i po kryzysie

W celu pogłębienia analizy oszacowano parametry funkcji trendu liniowego osobno dla okresu przed kryzysem i po wybuchu kryzysu, a następnie zweryfikowano hipotezę o istotności różnicy współczynników kierunkowych nachylenia β_1 :

- $H_0: \beta_{1,po} - \beta_{1,przed} = 0$ (tempo zmian przeładunków w obu okresach nie różniło się istotnie),
- $H_1: \beta_{1,po} - \beta_{1,przed} \neq 0$ (wystąpiła statystycznie istotna zmiana tempa / trendu).

```
# Indeksy czasowe t dla obu okresów
t_A <- 1:length(probka_A)
t_B <- (length(probka_A) + 1):nrow(dane)

model_A <- lm(probka_A ~ t_A)
model_B <- lm(probka_B ~ t_B)

b1_A <- coef(model_A)[2]
b1_B <- coef(model_B)[2]

se_A <- summary(model_A)$coefficients[2, 2]
se_B <- summary(model_B)$coefficients[2, 2]

# Różnica współczynników i łączny błąd standardowy
delta_beta <- b1_B - b1_A
se_diff <- sqrt(se_A^2 + se_B^2)
t_stat_beta <- delta_beta / se_diff
df_beta <- min(length(probka_A) - 2, length(probka_B) - 2)
p_val_beta <- 2 * pt(-abs(t_stat_beta), df = df_beta)

wyniki_trendow <- data.frame(
  Parametr = c("Trend przed 2022 (beta_1A)",
               "Trend po 2022 (beta_1B)",
               "Różnica nachyleń (beta_1B - beta_1A)"),
  Wartosc = c(sprintf("%.4f tys. t/miesiąc", b1_A),
               sprintf("%.4f tys. t/miesiąc", b1_B),
               sprintf("%.4f", delta_beta)),
  SE = c(sprintf("%.4f", se_A), sprintf("%.4f", se_B), sprintf("%.4f",
se_diff)),
  t = c("-", "-", sprintf("%.4f", t_stat_beta)),
  p_val = c("-", "-", sprintf("%.4e", p_val_beta)),
  Decyzja = c("-", "-", "Odrzucenie H0 (p < 0.05)")
)
colnames(wyniki_trendow) <- c("Parametr trendu", "Wartość oszacowana", "Błąd
std. (SE)", "Statystyka t", "p-value", "Decyzja")

knitr::kable(wyniki_trendow, caption = "Tabela 5. Porównanie nachyleń linii
regresji liniowej przed i po 2022 r.")
```

Tabela 5. Porównanie nachyleń linii regresji liniowej przed i po 2022 r.

Parametr trendu	Wartość oszacowana	Błąd std. (SE)	Statystyka t	p-value	Decyzja
Trend przed 2022 (beta_1A)	0.3840 tys. t/miesiąc	0.4538	-	-	-
Trend po 2022 (beta_1B)	-26.7026 tys. t/miesiąc	5.0857	-	-	-
Różnica nachyleń (beta_1B - beta_1A)	-27.0866	5.1059	-5.3049	2.249 8e-06	Odrzucenie H0 (p < 0.05)

Wniosek: Różnica między nachyleniami linii regresji jest statystycznie wysoce istotna ($t = -5.3049$, $p < 0,001$). O ile w latach 2010–2021 trend był lekko dodatni ($\beta_{1,A} = +0,38$), o tyle po 2022 roku – po gwałtownym skoku na początku wojny – trend uległ odwróceniu i stał się silnie spadkowy ($\beta_{1,B} = -26,70$), co obrazuje proces normalizacji zapasów węgla i wycofywania się z nadzwyczajnych zakupów interwencyjnych.

V. Komentarz do uzyskanych wyników

Przeprowadzona analiza statystyczna pozwoliła sformułować następujące wnioski:

1. **Charakterystyka rozkładu empirycznego:** Przetładunki węgla i koksu w polskich portach morskich w latach 2010–2026 cechują się wyraźną asymetrią prawostronną ($\gamma_1 = 2,87$) oraz silną leptokurtozą ($\beta_2 = 13,37$). Wynika to z faktu, że typowy wolumen przetładunków wynosił ok. 700–900 tys. ton miesięcznie, a okres kryzysu energetycznego przyniósł bezprecedensowe skoki do poziomów przekraczających 3,4 mln ton.
2. **Duża zmienność procesów portowych:** Klasyczny współczynnik zmienności na poziomie ok. 48,9% świadczy o wysokiej podatności przetładunków na czynniki zewnętrzne (sezon grzewczy zimą, cykle koniunkturalne hutnictwa i energetyki, wstrząsy geopolityczne). Pozycyjny współczynnik zmienności ($V_Q \approx 18,15\%$) dowodzi natomiast, że standardowa działalność operacyjna portów była stabilna, a za wysoką wariancję odpowiadały przede wszystkim anomalie z lat 2022–2023.
3. **Potwierdzenie korelacji (Hipoteza 1):** Odrzucenie hipotezy zerowej o braku korelacji ($r = 0,863$, $p < 0,001$) udowadnia, że dynamika ładunków masowych suchych ogółem w polskich portach morskich jest bezpośrednio i ściśle determinowana przez węgiel i koks.
4. **Wpływ kryzysu energetycznego (Hipoteza 2):** Wyniki dwupróbowego testu t-Studenta ($p < 0,001$) oraz testu nachyleń regresji jednoznacznie potwierdzają hipotezę o wystąpieniu statystycznie istotnej zmiany średnich przetładunków i kierunku trendu po wybuchu wojny w Ukrainie w 2022 roku. Średnie miesięczne obroty wzrosły o ponad 45% (z 836,9 do 1219,4 tys. ton).
5. **Normalizacja rynku w latach 2024–2026:** Analiza szeregu czasowego i ujemny współczynnik kierunkowy regresji po 2022 r. ($\beta_1 = -26,70$) dokumentują proces wygaszania paniki surowcowej, wypełnienie krajowych magazynów i powrót obrotów węglem do poziomów zrównoważonych.

VI. Listing komend generujących wyniki

Poniższy listing zawiera uporządkowane komendy środowiska **R** wykorzystane do wygenerowania wszystkich rezultatów obliczeniowych, testów statystycznych oraz wykresów.

```
#
=====
=
# PROJEKT: STATYSTYCZNA ANALIZA DANYCH - PRZELADUNKI WĘGLA I KOKSU
# LISTING KOMEND ŚRODOWISKA R
#
=====
=

# 1. Pakiety
library(readxl)
library(ggplot2)
library(moments)
library(knitr)
library(pander)

# 2. Wczytanie i przygotowanie danych
dane <-
as.data.frame(readxl::read_excel("dane_wegiel_koks_porty_2010_2026.xlsx"))
dane$data <- as.Date(dane$data)
dane$okres_badiania <- factor(dane$okres_badiania)
x <- dane$wegiel_koks_tys_ton

# 3. Podstawowe parametry opisowe
mean(x)                                # Średnia arytmetyczna
sd(x)                                  # Odchylenie standardowe
var(x)                                 # Wariancja
(sd(x) / mean(x)) * 100                # Współczynnik zmienności
klasyczny V (%)
mad(x, center = median(x))            # Odchylenie przeciętne
medianowe (MAD)
moments::skewness(x)                  # Skośność (asymetria)
moments::kurtosis(x)                  # Kurtoza (koncentracja)
dens <- density(x)                    # Estymacja gęstości
dens$x[which.max(dens$y)]              # Estymowana moda
(dominanta)

# Miary pozycyjne i kwantyle
min(x)                                # Minimum
quantile(x, 0.25)                      # Kwantyl 1 (Q1)
median(x)                              # Mediana (Q2)
quantile(x, 0.75)                      # Kwantyl 3 (Q3)
max(x)                                # Maksimum
```

```

max(x) - min(x) # Rozstęp całkowity (R)
IQR(x) # Rozstęp międzykwartyłowy
(IQR)
((IQR(x) / 2) / median(x)) * 100 # Pozycyjny współczynnik
zmienności V_Q (%)

# 4. Graficzna prezentacja danych
# Histogram z krzywą gęstości
ggplot(dane, aes(x = wegciel_koks_tys_ton)) +
  geom_histogram(aes(y = after_stat(density)), bins = 25, fill = "#2c3e50") +
  geom_density(color = "#e74c3c", linewidth = 1.1)

# Wykres pudełkowy (Boxplot)
ggplot(dane, aes(x = okres_badania, y = wegciel_koks_tys_ton, fill =
okres_badania)) +
  geom_boxplot() + stat_summary(fun = mean, geom = "point", shape = 18)

# Dystrybuanta empiryczna (ECDF)
ggplot(dane, aes(x = wegciel_koks_tys_ton, color = okres_badania)) +
  stat_ecdf(geom = "step", linewidth = 1.1)

# Szereg czasowy ze wstępną trendu LOESS
ggplot(dane, aes(x = data, y = wegciel_koks_tys_ton)) +
  geom_line() + geom_smooth(method = "loess")

# Wykres rozrzutu z prostą regresji liniowej
ggplot(dane, aes(x = masowe_suche_tys_ton, y = wegciel_koks_tys_ton)) +
  geom_point() + geom_smooth(method = "lm")

# 5. Weryfikacja hipotez statystycznych
# Weryfikacja normalności rozkładu
shapiro.test(dane$wegciel_koks_tys_ton)
shapiro.test(dane$masowe_suche_tys_ton)

# Hipoteza 1: Test korelacji (Pearson i Spearman)
cor.test(dane$wegciel_koks_tys_ton, dane$masowe_suche_tys_ton, method =
"pearson")
cor.test(dane$wegciel_koks_tys_ton, dane$masowe_suche_tys_ton, method =
"spearman")

# Hipoteza 2: Porównanie dwóch okresów (okres stabilny vs kryzysowy)
probka_A <- dane$wegciel_koks_tys_ton[dane$rok < 2022]
probka_B <- dane$wegciel_koks_tys_ton[dane$rok >= 2022]

var.test(probka_A, probka_B) # Test jednorodności
wariancji F
t.test(probka_A, probka_B, var.equal = FALSE) # Test t-Studenta (z korektą
Welcha)

```

```
# Regresje liniowe w podokresach i test różnicy nachyleń  
lm_A <- lm(probka_A ~ seq_along(probka_A))  
lm_B <- lm(probka_B ~ seq_along(probka_B))  
summary(lm_A)  
summary(lm_B)
```

VII. Opis użytych funkcji środowiska R

Poniższa tabela przedstawia szczegółowy opis wszystkich funkcji języka **R** oraz bibliotek wykorzystanych w niniejszym opracowaniu, wraz ze wskazaniem dokładnego pakietu źródłowego.

Tabela 6. Zestawienie funkcji środowiska R wykorzystanych w projekcie

Funkcja / Narzędzie	Opis działania funkcji	Pakiet
<code>readxl::read_excel()</code>	Import danych z arkuszy kalkulacyjnych Microsoft Excel (.xlsx)	readxl
<code>mean()</code>	Obliczanie średniej arytmetycznej próby	base
<code>sd()</code>	Obliczanie próbowego odchylenia standardowego	stats
<code>var()</code>	Obliczanie wariancji próbkowej (miary dyspersji z mianownikiem $n - 1$)	stats
<code>median()</code>	Wyznaczanie mediany – wartości środkowej dzielącej próbę na dwie równe części	stats
<code>quantile()</code>	Wyznaczanie kwantyli dowolnego rzędu (np. kwartyli Q1, Q3)	stats
<code>IQR()</code>	Obliczanie rozstępu międzykwartylowego ($IQR = Q3 - Q1$)	stats
<code>mad()</code>	Obliczanie medianowego odchylenia bezwzględnego (MAD)	stats
<code>min()</code> / <code>max()</code>	Wyszukiwanie wartości minimalnej oraz maksymalnej w wektorze	base
<code>moments::skewness()</code>	Obliczanie współczynnika skośności – miary asymetrii rozkładu	moments
<code>moments::kurtosis()</code>	Obliczanie kurtozy – miary koncentracji i spiczastości rozkładu	moments
<code>density()</code>	Wyznaczanie jądrowego estymatora gęstości (estymacja mody)	stats
<code>shapiro.test()</code>	Weryfikacja hipotezy o normalności rozkładu testem Shapiro-Wilka	stats
<code>cor.test()</code>	Weryfikacja istotności współczynnika korelacji Pearsona / Spearmana	stats
<code>var.test()</code>	Testowanie hipotezy o równości wariancji testem F Fishera-Snedecora	stats
<code>t.test()</code>	Weryfikacja hipotezy o równości średnich testem t-Studenta (Welcha)	stats

Funkcja / Narzędzie	Opis działania funkcji	Pakiet
lm()	Dopasowywanie modeli regresji liniowej metodą najmniejszych kwadratów	stats
summary()	Generowanie szczegółowego raportu z modelu regresji (SE, t, R ² , p)	base
coef()	Ekstrakcja wektora współczynników kierunkowych z modelu liniowego	stats
pt()	Obliczanie dystrybuanty teoretycznej rozkładu t-Studenta	stats
ggplot()	Inicjalizacja wykresu opartego na gramatyce grafiki (Grammar of Graphics)	ggplot2
geom_histogram()	Dodawanie warstwy histogramu z podziałem na przedziały klasowe	ggplot2
geom_density()	Dodawanie warstwy gładkiej krzywej estymatora gęstości rozkładu	ggplot2
geom_boxplot()	Tworzenie wykresów pudełkowych (Boxplot) z identyfikacją outlierów	ggplot2
stat_ecdf()	Tworzenie schodkowej krzywej dystrybuanty empirycznej (ECDF)	ggplot2
geom_line() / geom_point()	Dodawanie warstw wykresów liniowych i punktowych (szeregi czasowe, rozrzut)	ggplot2
geom_smooth()	Dopasowywanie i rysowanie wygładzonych linii trendu (LOESS, LM)	ggplot2
geom_vline() / annotate()	Dodawanie pionowych linii referencyjnych na osi czasu oraz adnotacji	ggplot2
knitr::kable()	Formatowanie ramek danych R do postaci estetycznych tabel w raporcie	knitr
pander::pander()	Zaawansowane formatowanie obiektów i wyników testów w raportach knitr	pander

Podsumowanie i wnioski końcowe

Przeprowadzona analiza statystyczna pozwoliła na szczegółowe zbadanie dynamiki obrotów węglem i koksem w polskich portach morskich w latach 2010–2026. Zastosowanie różnorodnych miar statystyki opisowej, technik wizualizacji oraz parametrycznych i nieparametrycznych testów weryfikacji hipotez umożliwiło precyzyjne uchwycenie skali i charakteru wstrząsu geopolitycznego oraz procesu późniejszej stabilizacji rynku. Wszystkie etapy badania zrealizowano w środowisku obliczeniowym R, zapewniając pełną powtarzalność i przejrzystość uzyskanych rezultatów.