



**POLITECHNIKA
RZESZOWSKA**
im. IGNACEGO ŁUKASIEWICZA

WYDZIAŁ MATEMATYKI I FIZYKI STOSOWANEJ

Projekt:

Wpływ internetu i mediów społecznościowych na popularyzację szachów:

Analiza statystyczna

Rafał Bazan

Rzeszów 2025

Spis treści

I Opis użytych danych.....	3
II Wyznaczenie podstawowych parametrów opisowych	5
Kod:.....	5
Wartości parametrów:	5
Opis parametrów, dla liczby zagranych partii w zależności od miesiąca (dane zredukowane do 0,001% pierwotnej wartości):.....	5
III Graficzna prezentację danych	7
Wykres słupkowy.....	7
IV Weryfikacja hipotez statystycznych	9
Hipoteza 1	9
Hipoteza 2	12
V Listing komend generujących wyniki	27
VI Opis użytych funkcji środowiska R	28

I Opis użytych danych

Źródło danych: Dane wykorzystane w prezentacji pochodzą z bazy danych platformy szachowej Lichess, dostępnej pod adresem <https://database.lichess.org>. Są to publicznie dostępne zbiory danych zawierające informacje o partiach szachowych rozegranych na tej platformie. Dane pobierane były w formacie PGN (Portable Game Notation) oraz w formacie .zst.torrent, które obejmują zarówno metadane partii, jak i pełne zapisy ruchów.

Scrapowanie danych przeprowadzono przy użyciu języka R, korzystając z bibliotek takich jak rvest, stringi, dplyr czy ggplot2, a dane pobierano z konkretnej tabeli na stronie Lichess (ścieżka XPath: /html/body/div/div[2]/div[2]/section[1]/table).

Dane zostały zredukowane do 0,001% ich pierwotnej wartości ze względu na dużą ilość.

Czego dotyczą dane: Dane dotyczą partii szachowych rozegranych na platformie Lichess od 2013 roku do kwietnia 2024 roku. Obejmują one:

- **Liczbę rozegranych partii:** Informacje o liczbie gier w danym miesiącu.
- **Metadane partii:** Informacje takie jak data, rok, miesiąc, rodzaj debiutu (np. [Opening „Sicilian Defense: Old Sicilian”]), rankingi ELO graczy (np. WhiteElo, BlackElo), oraz sekwencje ruchów w notacji algebraicznej.

Sample

```
[Event "Rated Bullet tournament https://lichess.org/tournament/yc1ww20x"]
[Site "https://lichess.org/PpwPOZMq"]
[Date "2017.04.01"]
[Round "-"]
[White "Abbot"]
[Black "Costello"]
[Result "0-1"]
[UTCDate "2017.04.01"]
[UTCTime "11:32:01"]
[WhiteElo "2100"]
[BlackElo "2000"]
[WhiteRatingDiff "-4"]
[BlackRatingDiff "+1"]
[WhiteTitle "FM"]
[ECO "B30"]
[Opening "Sicilian Defense: Old Sicilian"]
[TimeControl "300+0"]
[Termination "Time forfeit"]

1. e4 { [%eval 0.17] [%clk 0:00:30] } 1... c5 { [%eval 0.19] [%clk 0:00:30] }
2. Nf3 { [%eval 0.25] [%clk 0:00:29] } 2... Nc6 { [%eval 0.33] [%clk 0:00:30] }
3. Bc4 { [%eval -0.13] [%clk 0:00:28] } 3... e6 { [%eval -0.04] [%clk 0:00:30] }
4. c3 { [%eval -0.4] [%clk 0:00:27] } 4... b5? { [%eval 1.18] [%clk 0:00:30] }
5. Bb3?! { [%eval 0.21] [%clk 0:00:26] } 5... c4 { [%eval 0.32] [%clk 0:00:29] }
6. Bc2 { [%eval 0.2] [%clk 0:00:25] } 6... a5 { [%eval 0.6] [%clk 0:00:29] }
7. d4 { [%eval 0.29] [%clk 0:00:23] } 7... cxd3 { [%eval 0.6] [%clk 0:00:27] }
8. Qxd3 { [%eval 0.12] [%clk 0:00:22] } 8... Nf6 { [%eval 0.52] [%clk 0:00:26] }
9. e5 { [%eval 0.39] [%clk 0:00:21] } 9... Nd5 { [%eval 0.45] [%clk 0:00:25] }
10. Bg5?! { [%eval -0.44] [%clk 0:00:18] } 10... Qc7 { [%eval -0.12] [%clk 0:00:20] }
11. Nbd2?? { [%eval -3.15] [%clk 0:00:14] } 11... h6 { [%eval -2.99] [%clk 0:00:18] }
12. Bh4 { [%eval -3.0] [%clk 0:00:11] } 12... Ba6? { [%eval -0.12] [%clk 0:00:16] }
13. b3?? { [%eval -4.14] [%clk 0:00:02] } 13... Nf4? { [%eval -2.73] [%clk 0:00:05] }
```

Rysunek 1

Filter	
▲	V1
1	[Event "Rated Classical game"]
2	[Site "https://lichess.org/j1dkb5dw"]
3	[White "BFG9k"]
4	[Black "mamalak"]
5	[Result "1-0"]
6	[UTCDate "2012.12.31"]
7	[UTCTime "23:01:03"]
8	[WhiteElo "1639"]
9	[BlackElo "1403"]
10	[WhiteRatingDiff "+5"]
11	[BlackRatingDiff "-8"]
12	[ECO "C00"]
13	[Opening "French Defense: Normal Variation"]
14	[TimeControl "600+8"]
15	[Termination "Normal"]
16	1. e4 e6 2. d4 b6 3. a3 Bb7 4. Nc3 Nh6 5. Bxh6 gxh6 6. Be2 ...
17	[Event "Rated Classical game"]
Showing 1 to 18 of 2,174 entries, 1 total columns	

Uzasadnienie wyboru danych:

- **Lichess jako źródło:** Lichess jest jedną z najpopularniejszych platform szachowych online, oferującą ogromną bazę danych partii, co czyni ją reprezentatywnym źródłem do analizy trendów w szachach cyfrowych. Publiczna dostępność i duża liczba partii (np. 91–98 milionów miesięcznie w 2024 roku) zapewniają solidną podstawę do badań.
- Dane te umożliwiły wyciągnięcie wniosków dotyczących wzrostu popularności szachów, wpływu serialu "Gambit królowej" oraz efektu nowych debiutów na zaangażowanie graczy.

II Wyznaczenie podstawowych parametrów opisowych

Kod:

```
# Obliczanie parametrów statystycznych i drukowanie ich z komentarzami
cat("Średnia arytmetyczna (wartość centralna danych, średnia liczba partii w miesiącu): ", mean(my_games_count), "\n")
cat("Odchylenie standardowe (miara rozproszenia danych wokół średniej): ", sd(my_games_count), "\n")
cat("Współczynnik zmienności (relatywna miara zmienności w procentach): ", (sd(my_games_count) / mean(my_games_count))
* 100, "\n")
cat("Kwartył 1 (wartość, poniżej której znajduje się 25% danych): ", quantile(my_games_count, probs = 0.25), "\n")
cat("Mediana (wartość środkowa po posortowaniu danych): ", median(my_games_count), "\n")
cat("Kwartył 3 (wartość, poniżej której znajduje się 75% danych): ", quantile(my_games_count, probs = 0.75), "\n")
cat("Odchylenie przeciętne (miara rozproszenia oparta na medianie odchyłeń od średniej): ", mad(my_games_count, center
= mean(my_games_count)), "\n")
cat("Wariancja (kwadrat odchylenia standardowego, miara całkowitej zmienności): ", var(my_games_count), "\n")
cat("Maksimum (najwyższa wartość w zbiorze danych): ", max(my_games_count), "\n")
cat("Minimum (najniższa wartość w zbiorze danych): ", min(my_games_count), "\n")
cat("Rozstęp (różnica między maksymalną a minimalną wartością): ", max(my_games_count) - min(my_games_count), "\n")
cat("Kurtoza (miara spiczastości rozkładu danych): ", kurtosis(my_games_count), "\n")
cat("Skośność (miara asymetrii rozkładu danych): ", skewness(my_games_count), "\n")
dens <- density(my_games_count)
cat("Estymowana moda (na podstawie gęstości): ", dens$x[which.max(dens$y)], "\n")
...

```

```
Średnia arytmetyczna (wartość centralna danych, średnia liczba partii w miesiącu): 40905841
Odchylenie standardowe (miara rozproszenia danych wokół średniej): 39574779
Współczynnik zmienności (relatywna miara zmienności w procentach): 96.74604
Kwartył 1 (wartość, poniżej której znajduje się 25% danych): 3546937
Mediana (wartość środkowa po posortowaniu danych): 22803791
Kwartył 3 (wartość, poniżej której znajduje się 75% danych): 89206252
Odchylenie przeciętne (miara rozproszenia oparta na medianie odchyłeń od średniej): 58031581
Wariancja (kwadrat odchylenia standardowego, miara całkowitej zmienności): 1.566163e+15
Maksimum (najwyższa wartość w zbiorze danych): 108201825
Minimum (najniższa wartość w zbiorze danych): 121332
Rozstęp (różnica między maksymalną a minimalną wartością): 108080493
Kurtoza (miara spiczastości rozkładu danych): 1.449067
Skośność (miara asymetrii rozkładu danych): 0.4261488
Estymowana moda (na podstawie gęstości): 6864736

```

Rysunek 2

Wartości parametrów:


Opis parametrów, dla liczby zagranych partii w zależności od miesiąca (dane zredukowane do 0,001% pierwotnej wartości):

- **Średnia arytmetyczna (40,905,841):** Średnio w miesiącu rozgrywa się około 40,9 miliona partii szachowych, co stanowi centralną wartość danych i pokazuje typową liczbę partii.
- **Odchylenie standardowe (39,574,779):** Wysoka wartość około 39,6 miliona wskazuje na duże rozproszenie danych wokół średniej, sugerując znaczne różnice w liczbie partii między miesiącami.
- **Współczynnik zmienności (96.75%):** Wartość bliska 100% oznacza bardzo dużą zmienność liczby partii w stosunku do średniej.
- **Kwartył 1 (3,546,937):** 25% miesięcy ma mniej niż 3,5 miliona partii, co pokazuje, że w dolnym kwartale dane są stosunkowo niskie.

- **Mediana (22,803,791):** Wartość środkowa wynosi 22,8 miliona partii, co oznacza, że połowa miesięcy ma mniej, a połowa więcej niż ta liczba.
- **Kwartyl 3 (89,206,252):** 75% miesięcy ma mniej niż 89,2 miliona partii, wskazując, że większość danych mieści się poniżej tej wartości, ale górny kwartał jest wysoki.
- **Odchylenie przeciętne (58,031,581):** Wartość 58 milionów potwierdza dużą zmienność danych, mierząc średnie odchylenie od mediany.
- **Wariancja (1.566163e+15):** Ogromna wartość wariancji (1,57 biliona) podkreśla znaczną całkowitą zmienność liczby partii w miesiącach.
- **Maksimum (108,201,825):** Najwyższa liczba partii w jednym miesiącu to 108,2 miliona, co pokazuje szczytowy wynik w danych.
- **Minimum (121,332):** Najniższa liczba partii wynosi zaledwie 121,332, co wskazuje na ekstremalnie niski poziom w niektórych miesiącach.
- **Rozstęp (108,080,493):** Różnica między maksimum a minimum (108,1 miliona) ilustruje bardzo szeroki zakres liczby partii w danych.
- **Kurtoza (1.449067):** Dodatnia wartość kurtozy (1,45) sugeruje, że rozkład danych jest bardziej spiczasty niż rozkład normalny, z wyraźnym szczytem.
- **Skośność (0.4261488):** Lekko dodatnia skośność (0,43) wskazuje na asymetrię w prawo, czyli więcej miesięcy z niższą liczbą partii i kilka z bardzo wysokimi wartościami.
- **Estymacja mody (6864736):** Podany kod oblicza modę dla zmiennej `my_games_count`. Jednak w tym konkretnym zbiorze danych, gdzie wszystkie wartości są unikalne, moda nie jest szczególnie informatywna. W takich przypadkach warto rozważyć estymację mody na podstawie gęstości lub grupowanie danych w przedziały, aby lepiej uchwycić najczęściej występujący zakres wartości.



III Graficzna prezentację danych

Wykres słupkowy



Opis: Ten wykres przedstawia liczbę partii szachowych granych na stronie Lichess w okresie od 2013 do 2024 roku (bez redukcji). Wykres jest typu słupkowego, gdzie każda kolumna odpowiada danemu roku, a wysokość słupka wskazuje liczbę partii szachowych (w milionach) zagranych w danym roku. Kolory różnią się dla każdego roku, co pozwala na łatwe rozróżnienie danych w czasie. Wykres pokazuje wyraźny wzrost liczby partii, zwłaszcza od 2020 roku, co może być związane z większym zainteresowaniem szachami.

Termin „debiut”, który się przydaje w dalszej prezentacji oznacza nazewnictwo początkowej sekwencji ruchów.
Przykłady:



IV Weryfikacja hipotez statystycznych

Hipoteza 1

W pierwszej hipotezie sprawdzimy, czy istnieje statystycznie istotna korelacja między całkowitą liczbą rozegranych partii szachowych a liczbą partii wykorzystujących debiuty „gambit królowej” lub „partię włoską”. Potwierdzenie takiej korelacji może świadczyć o związku popularności tych debiutów z ogólną aktywnością graczy.

- Hipoteza zerowa (H0): Nie istnieje statystycznie istotna korelacja między całkowitą liczbą partii a liczbą partii z debiutem „gambit królowej” lub „partia włoska”.
- Hipoteza alternatywna (H1): Istnieje statystycznie istotna korelacja między całkowitą liczbą partii a liczbą partii z debiutem „gambit królowej” lub „partia włoska”.

```
#pierwsza hipoteza
shapiro_total <- shapiro.test(my_games_count)
shapiro_gambit <- shapiro.test(games_count_gambit)
shapiro_gambit <- shapiro.test(games_count_italian)
pander(shapiro_total, caption = "Test Shapiro-Wilk dla liczby wszystkich partii")
pander(shapiro_gambit, caption = "Test Shapiro-Wilk dla liczby zagranych debiutów 'Gambit Królowej'")
pander(shapiro_gambit, caption = "Test Shapiro-Wilk dla liczby zagranych debiutów 'Partia Włoska'")
```

Rysunek 3

Test statistic	P value
0.8135745	7.348187e-12 * * *

Table: Test Shapiro-wilk dla liczby wszystkich partii

Test statistic	P value
0.8171664	9.934141e-12 * * *

Table: Test Shapiro-wilk dla liczby zagranych debiutów 'Gambit Królowej'

Test statistic	P value
0.8171664	9.934141e-12 * * *

Table: Test Shapiro-wilk dla liczby zagranych debiutów 'Partia Włoska'

Test Shapiro-Wilka dla wszystkich analizowanych zbiorów danych:

- Test Shapiro-Wilka dla liczby wszystkich zagranych partii:
 - Statystyka testu: 0.8135745

- Wartość p: 7.348187e-12
- Wniosek: Bardzo niska wartość p (< 0.05) wskazuje na odrzucenie hipotezy zerowej (H_0) na poziomie istotności 0.05. Oznacza to, że dane dotyczące całkowitej liczby zagranich partii szachowych nie mają rozkładu normalnego. Rozkład danych jest istotnie różny od normalnego, co może sugerować obecność skośności (np. dodatniej, z dłuższym ogonem w kierunku wyższych wartości) lub wartości odstających.
- **Test Shapiro-Wilka dla podzbioru 'Gambit Królowej':**
 - Statystyka testu: 0.817164
 - Wartość p: 9.9341e-12
 - Wniosek: Podobnie jak w przypadku wszystkich partii, wartość p jest znacznie poniżej 0.05, co prowadzi do odrzucenia hipotezy zerowej (H_0). Dane dotyczące liczby partii z gambitem królowej również nie podążają za rozkładem normalnym, wskazując na istotne odchylenia od normalności, takie jak skośność lub wartości ekstremalne.
- **Test Shapiro-Wilka dla podzbioru 'Partia Włoska':**
 - Statystyka testu: 0.817164
 - Wartość p: 9.9341e-12
 - Wniosek: Identyczna wartość statystyki i p-value jak dla gambitu królowej sugeruje, że dane dotyczące liczby partii z partią włoską również nie mają rozkładu normalnego. Odrzucenie hipotezy zerowej (H_0) na poziomie istotności 0.05 potwierdza obecność istotnych odchyżeń od normalności, podobnych do tych obserwowanych w innych zbiorach.

Ogólna interpretacja:

- Brak normalności rozkładu we wszystkich trzech zbiorach danych (wszystkie partie, gambit królowej, partia włoska) wskazuje na możliwe skośności (np. dodatnie, z dłuższym ogonem w kierunku większych wartości) lub obecność wartości odstających. To może wynikać z nierównomiernej popularności debiutów w czasie lub wpływu zewnętrznych czynników, takich jak premiera serialu *Gambit królowej*.
- Wyniki te mają implikacje dla dalszych analiz statystycznych. Metody parametryczne, takie jak test t lub korelacja Pearsona, mogą być niewiarygodne z powodu nienormalnego rozkładu danych. Zamiast tego zaleca się użycie metod nieparametrycznych, np. testu Mann-Whitney'ego, testu Wilcoxa lub korelacji Spearmana.
- Obecność podobnych wartości statystyki i p-value dla gambitu królowej i partii włoskiej może sugerować, że oba debiuty wykazują podobne wzorce odchyżeń od normalności, co może być związane z ogólną dynamiką popularności szachów w analizowanym okresie (2013–2024).
- Te wyniki wspierają potrzebę dalszej analizy, np. badania korelacji między popularnością różnych debiutów i całkowitą liczbą partii, z uwzględnieniem nienormalnego charakteru danych, aby lepiej zrozumieć wpływ czynników takich jak serial na trendy w szachach.

```
pander(correlation_gambit <- cor.test(my_games_count, games_count_gambit), caption = "Test korelacji spearmana między  
liczbą wszystkich partii a gambitem królowej",method = "spearman")  
pander(correlation_italian <- cor.test(my_games_count, games_count_italian), caption = "Test korelacji spearmana  
między liczbą wszystkich partii a partią włoską",method = "spearman")
```

Test statistic	df	P value	Alternative hypothesis	cor
133.4362	134	2.240533e-144 * * *	two.sided	0.9962582

Table: Test korelacji spearmana między liczbą wszystkich partii a gambitem królowej

Test statistic	df	P value	Alternative hypothesis	cor
120.5478	134	1.63351e-138 * * *	two.sided	0.9954211

Table: Test korelacji spearmana między liczbą wszystkich partii a partią włoską

□ Korelacja liczby zagrzanych debiutów Partia Gambit Królowej względem wszystkich partii:


- **Statystyka testu:** 133.4362
- **Stopnie swobody (df):** 134
- **Wartość p:** 2.24053e-144
- **Korelacja (cor):** 0.9962582
- **Wniosek:** Bardzo niska wartość p (< 0.05) wskazuje na statystycznie istotną korelację. Wysoka wartość współczynnika korelacji Spearmana (0.9962582) sugeruje niemal doskonałą dodatnią korelację liniową między liczbą wszystkich zagrzanych partii a liczbą partii z gambitem królowej. Oznacza to, że wraz ze wzrostem ogólnej liczby partii, liczba partii z gambitem królowej rośnie w bardzo podobnym tempie.

□ Korelacja liczby zagrzanych debiutów Partia Włoska względem wszystkich partii:

- **Statystyka testu:** 120.5478
- **Stopnie swobody (df):** 134
- **Wartość p:** 1.63351e-138
- **Korelacja (cor):** 0.9954211
- **Wniosek:** Podobnie jak w przypadku gambitu królowego, wartość p jest niezwykle niska (< 0.05), co potwierdza statystyczną istotność korelacji. Współczynnik korelacji Spearmana (0.9954211) również wskazuje na bardzo silną dodatnią korelację liniową między liczbą wszystkich partii a liczbą partii z partią włoską. Oznacza to, że popularność partii włoskiej rośnie w sposób niemal proporcjonalny do ogólnej liczby zagrzanych partii.

□ Ogólna interpretacja:

- Na podstawie przeprowadzonej analizy statystycznej odrzucamy hipotezę zerową (H_0) i przyjmujemy hipotezę alternatywną (H_1), co oznacza, że istnieje statystycznie istotna korelacja między całkowitą liczbą rozegranych partii szachowych a liczbą partii z debiutem „gambit królowej” lub „partia włoska”. Wysokie wartości współczynników korelacji, bliskie 1, wskazują na silny związek między ogólną aktywnością szachową a częstotliwością stosowania tych debiutów.
- Jednak należy zauważyć, że wysoka korelacja nie implikuje przyczynowości – wzrost liczby partii z tymi debiutami może wynikać z ogólnego wzrostu popularności szachów, a niekoniecznie z preferencji samych debiutów.



Ponieważ korelacja liczby zagranych debiutów Partia Włoska i Gambit Królowej względem wszystkich partii jest wysoka, dane te możemy wykorzystać do dalszej analizy w ramach drugiej hipotezy, badając, czy kluczowe wydarzenia medialne i rozwój mediów wpłynęły na różnice w tempie wzrostu popularności tych debiutów ($\beta_{1_po} - \beta_{1_przed} \neq 0$).

Hipoteza 2

Badamy, czy kluczowe wydarzenia medialne (np. premiera serialu „Gambit królowej”), rozwój internetu i mediów społecznościowych wpłynęły na zmianę tempa wzrostu liczby partii z debiutami „gambit królowej”, „partiā włoską” oraz najnowszymi debiutami. Sprawdzamy, czy nachylenia linii regresji przed i po tych wydarzeniach (β_{1_przed} i β_{1_po}) różnią się istotnie, czyli czy różnica $\beta_{1_po} - \beta_{1_przed} \neq 0$.

- Hipoteza zerowa (H_0): $\beta_{1_po} - \beta_{1_przed} = 0$ (brak wpływu wydarzeń i mediów na popularyzację szachów)
- Hipoteza alternatywna (H_1): $\beta_{1_po} - \beta_{1_przed} \neq 0$ (istotny wpływ wydarzeń i mediów na popularyzację szachów)

```

games_count_chrono <- rev(games_count_gambit)

# Podział
games_count_chrono_przed <- games_count_chrono[1:94] # przed czerwiec 2023
games_count_chrono_po <- games_count_chrono[95:136] # czerwiec 2023 - kwiecień 2024

# Czas
time_przed <- 1:94
time_po <- 95:136

# Regresje
reg_przed <- lm(games_count_chrono_przed ~ time_przed)
summary(reg_przed)
reg_po <- lm(games_count_chrono_po ~ time_po)
summary(reg_po)

# Wyciągnięcie współczynników regresji (nachylenia)
beta1_przed <- coef(reg_przed)[2]
beta1_po <- coef(reg_po)[2]
delta_beta <- beta1_po - beta1_przed
cat("Różnica między współczynnikami regresji (po - przed):", delta_beta, "\n")

# Standardowe błędy nachyleń
se_beta1_przed <- summary(reg_przed)$coefficients[2, 2]
se_beta1_po <- summary(reg_po)$coefficients[2, 2]

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)

# Wartość delta (np. o ile oczekujesz, że nachylenie jest większe po premierze)
delta <- 0 # Możesz ustawić np. delta = 50, jeśli chcesz sprawdzić konkretną różnicę

# Statystyka t dla różnicy nachyleń
t_stat <- (delta_beta - delta) / se_diff

# Stopnie swobody (przybliżenie)
df <- min(length(games_count_chrono_przed) - 2, length(games_count_chrono_po) - 2)

# Wartość p dla testu jednostronnego (H1: beta1_po < beta1_przed + delta)
# Poprawiony kierunek: lower.tail = TRUE, bo testujemy mniejsze nachylenie
p_value <- pt(t_stat, df, lower.tail = TRUE)
?pt

# Wyświetlenie wyników
cat("Statystyka t:", t_stat, "\n")
cat("Stopnie swobody:", df, "\n")
cat("Wartość p:", p_value, "\n")

plot(time, games_count_chrono, type = "l", xlab = "Miesiąc (1 = styczeń 2013, 136 = kwiecień 2024)",
      ylab = "Liczba gier z debiutem Gambit Królowej")
abline(reg_przed, col = "blue") # Linia regresji przed premiera
abline(reg_po, col = "red") # Linia regresji po premierze
abline(v = 94, lty = 2, col = "green") # Linia oznaczająca październik 2020 (data wydania serialu)
legend("topleft", legend = c("Linia regresji przed premierą", "Linia regresji po premierze",
                             "Data wydania serialu"),
      col = c("blue", "red", "green"), lty = c(1, 1, 2))

```

```

Call:
lm(formula = games_count_chrono_przed ~ time_przed)

Residuals:
    Min       1Q   Median       3Q      Max
-486.96 -304.08  -99.35   203.14 1312.12

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -591.26      80.95  -7.304 9.84e-11 ***
time_przed     28.63       1.48  19.347 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 389.3 on 92 degrees of freedom
Multiple R-squared:  0.8027,    Adjusted R-squared:  0.8006
F-statistic: 374.3 on 1 and 92 DF,  p-value: < 2.2e-16

Call:
lm(formula = games_count_chrono_po ~ time_po)

Residuals:
    Min       1Q   Median       3Q      Max
-458.72 -193.63  -31.68   122.44   604.03

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4134.979     365.927  11.300 5.07e-14 ***
time_po       -4.455       3.151   -1.414  0.165
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 247.5 on 40 degrees of freedom
Multiple R-squared:  0.04761,    Adjusted R-squared:  0.0238
F-statistic: 1.999 on 1 and 40 DF,  p-value: 0.1651

Różnica między współczynnikami regresji (po - przed): -33.08619
Statystyka t: -9.504461
Stopnie swobody: 40
Wartość p: 4.095366e-12

```

Analiza wyników

1. Regresja przed premierą (styczeń 2013 – październik 2020):

- **Nachylenie (beta1_przed):** 28.63 – liczba partii z gambitem królowej rosła średnio o 28.63 partii miesięcznie.
- **Istotność:** Wartość $p < 2e-16$ wskazuje na statystycznie istotny wzrost ($p < 0.05$).
- **R-kwadrat:** 0.8027 – model dobrze dopasowuje się do danych (80.27% zmienności wyjaśnione przez czas).

2. Regresja po premierze (listopad 2020 – kwiecień 2024):

- **Nachylenie (beta1_po):** -4.455 – liczba partii z gambitem królowej maleje średnio o 4.455 partii miesięcznie.
- **Istotność:** Wartość $p = 0.165$ wskazuje, że nachylenie nie jest statystycznie istotne ($p > 0.05$).

- **R-kwadrat:** 0.04761 – model bardzo słabo dopasowuje się do danych (tylko 4.76% zmienności wyjaśnione przez czas).


3. Porównanie nachyleń:

- **Różnica (beta1_po - beta1_przed):** -33.08619 – nachylenie po premierze jest mniejsze o 33.09 w porównaniu do okresu przed premierą.
- **Statystyka t:** -9.504461
- **Wartość p:** 4.095366e-12
- **Wniosek:** Bardzo niska wartość p (< 0.05) pozwala odrzucić hipotezę zerową. Różnica między nachyleniami jest statystycznie istotna, ale w przeciwnym kierunku niż zakładano w hipotezie alternatywnej – nachylenie po premierze jest mniejsze, a nie większe.

Wnioski:


- **Odwrótny efekt:** Wbrew hipotezie alternatywnej, po premierze serialu *Gambit Królowej* nachylenie linii regresji liczby partii z gambitem królowej zmalało (z 28.63 do -4.455), co sugeruje, że popularność tego debiutu nie wzrosła, a wręcz zaczęła maleć.
- **Brak istotności po premierze:** Nachylenie po premierze (-4.455) nie jest statystycznie istotne ($p = 0.165$), co oznacza, że spadek liczby partii z gambitem królowej nie jest wyraźnym trendem.
- **Możliwe przyczyny:**
 - Popularność szachów mogła wzrosnąć po premierze serialu, ale nie przełożyło się to na proporcjonalny wzrost liczby partii z gambitem królowej.
 - Inne czynniki (np. moda na inne debiuty, zmiany w preferencjach graczy) mogły wpłynąć na spadek popularności gambitu królowej.

Podsumowując, wydanie serialu *Gambit Królowej* nie zwiększyło popularności debiutu gambit królowej w sposób zgodny z hipotezą – trend liczby partii z tym debiutem osłabł po premierze.



```
# Boxplot porównujący dystrybucję przed i po
boxplot(games_count_chrono_przed, games_count_chrono_po, names = c("Przed", "Po"),
        col = c("lightblue", "lightgreen"),
        main = "Liczba partii z gambitem królowej przed i po premierze",
        ylab = "Liczba partii")
```

Liczba partii z gambitem królowej przed i po premierze



- Boxplot pokazuje rozkład danych: dolny i górny "wąs", dolny i górny "pudełko" (25 i 75 percentyl), oraz medianę (linia w pudełku).

- Pozwala szybko zobaczyć, czy wartości po premierze są generalnie wyższe, niż przed, i jak rozkładają się dane (czy są bardziej rozproszone, czy mają outliery).

Analiza danych liczby partii włoskich względem ogólnej liczby partii
(Kod bardzo podobny do poprzedniego)

```
games_count_chrono <- rev(games_count_italian)

# Podział
games_count_chrono_przed <- games_count_chrono[1:94] # przed czerwiec 2023
games_count_chrono_po <- games_count_chrono[95:136] # czerwiec 2023 - kwiecień 2024

# Czas
time_przed <- 1:94
time_po <- 95:136

# Regresje
reg_przed <- lm(games_count_chrono_przed ~ time_przed)
summary(reg_przed)
reg_po <- lm(games_count_chrono_po ~ time_po)
summary(reg_po)

# Wyciągnięcie współczynników regresji (nachylenia)
beta1_przed <- coef(reg_przed)[2]
beta1_po <- coef(reg_po)[2]
delta_beta <- beta1_po - beta1_przed
cat("Różnica między współczynnikami regresji (po - przed):", delta_beta, "\n")

# Standardowe błędy nachyleń
se_beta1_przed <- summary(reg_przed)$coefficients[2, 2]
se_beta1_po <- summary(reg_po)$coefficients[2, 2]

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)

# Wartość delta (np. o ile oczekujesz, że nachylenie jest większe po premierze)
delta <- 0 # Możesz ustawić np. delta = 50, jeśli chcesz sprawdzić konkretną różnicę

# Statystyka t dla różnicy nachyleń
t_stat <- (delta_beta - delta) / se_diff

# Stopnie swobody (przybliżenie)
df <- min(length(games_count_chrono_przed) - 2, length(games_count_chrono_po) - 2)

# Wartość p dla testu jednostronnego (H1: beta1_po < beta1_przed + delta)
# Poprawiony kierunek: lower.tail = TRUE, bo testujemy mniejsze nachylenie
p_value <- pt(t_stat, df, lower.tail = TRUE)

# Wyświetlenie wyników
cat("Statystyka t:", t_stat, "\n")
cat("Stopnie swobody:", df, "\n")
cat("Wartość p:", p_value, "\n")

plot(time, games_count_chrono, type = "l", xlab = "Miesiąc (1 = styczeń 2013, 136 = kwiecień 2024)",
      ylab = "Liczba gier z debiutem Partia Włoska")
abline(reg_przed, col = "blue") # Linia regresji przed premierą
abline(reg_po, col = "red") # Linia regresji po premierze
abline(v = 94, lty = 2, col = "green") # Linia oznaczająca październik 2020 (data wydania serialu)
legend("topleft", legend = c("Linia regresji przed premierą", "Linia regresji po premierze",
                             "Data wydania serialu"),
      col = c("blue", "red", "green"), lty = c(1, 1, 2))
```

```

Call:
lm(formula = games_count_chrono_przed ~ time_przed)

Residuals:
    Min       1Q   Median       3Q      Max
-364.1  -249.6  -118.7   141.1  1101.5

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -474.616     71.756  -6.614 2.42e-09 ***
time_przed   21.878       1.312  16.679 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 345.1 on 92 degrees of freedom
Multiple R-squared:  0.7515,    Adjusted R-squared:  0.7488
F-statistic: 278.2 on 1 and 92 DF,  p-value: < 2.2e-16

Call:
lm(formula = games_count_chrono_po ~ time_po)

Residuals:
    Min       1Q   Median       3Q      Max
-812.21  -210.43   -46.93   141.66   768.26

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2074.597     479.322   4.328 9.77e-05 ***
time_po      11.912       4.127   2.886 0.00626 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 324.2 on 40 degrees of freedom
Multiple R-squared:  0.1723,    Adjusted R-squared:  0.1517
F-statistic: 8.329 on 1 and 40 DF,  p-value: 0.00626

Różnica między współczynnikami regresji (po - przed): -9.965929
Statystyka t: -2.301205
Stopnie swobody: 40
Wartość p: 0.01333505

```

Wyniki regresji liniowej

1. Regresja przed premierą (styczeń 2013 – październik 2020):

- **Nachylenie (beta1_przed):** 21.878 – liczba partii włoskich rosła średnio o 21.878 partii miesięcznie.
- **Istotność:** Wartość $p < 2e-16$ wskazuje na statystycznie istotny wzrost ($p < 0.05$).
- **R-kwadrat:** 0.7515 – model dobrze dopasowuje się do danych (75.15% zmienności wyjaśnione przez czas).
- **Interpretacja:** W okresie przed premierą serialu popularność partii włoskiej stabilnie rosła w czasie, co może odzwierciedlać ogólny wzrost zainteresowania szachami.

2. Regresja po premierze (listopad 2020 – kwiecień 2024):

- **Nachylenie (beta1_po):** 11.912 – liczba partii włoskich nadal rośnie, ale wolniej, średnio o 11.912 partii miesięcznie.
- **Istotność:** Wartość $p = 0.00626$ wskazuje, że wzrost jest statystycznie istotny ($p < 0.05$).
- **R-kwadrat:** 0.1723 – model słabo dopasowuje się do danych (tylko 17.23% zmienności wyjaśnione przez czas).
- **Interpretacja:** Po premierze serialu wzrost liczby partii włoskich jest wolniejszy i mniej przewidywalny, co może wskazywać na większą zmienność lub inne czynniki wpływające na popularność tego debiutu.

3. Porównanie nachyleń:

- **Różnica (beta1_po - beta1_przed):** -9.965929 – nachylenie po premierze jest mniejsze o 9.97 w porównaniu do okresu przed premierą.
- **Statystyka t:** -2.301205
- **Stopnie swobody:** 40
- **Wartość p:** 0.01333505
- **Interpretacja:** Wartość $p = 0.0133$ (< 0.05) wskazuje, że różnica między nachyleniami jest statystycznie istotna. Wzrost liczby partii włoskich po premierze serialu zwolnił w porównaniu do okresu przed premierą.

Wnioski w kontekście ogólnej liczby partii

1. Trend przed premierą:

- Liczba partii włoskich rosła w tempie 21.878 partii miesięcznie, co jest zgodne z ogólnym wzrostem liczby partii szachowych w tym okresie (na podstawie wcześniejszych analiz). Wysoki R-kwadrat (0.7515) sugeruje, że ten wzrost był stabilny i silnie powiązany z upływem czasu, co może odzwierciedlać naturalny wzrost popularności szachów online.

2. Trend po premierze:

- Po premierze serialu tempo wzrostu liczby partii włoskich zmalało do 11.912 partii miesięcznie. Chociaż wzrost jest nadal istotny statystycznie, niższy R-kwadrat (0.1723) wskazuje na większą zmienność i słabsze dopasowanie modelu liniowego. Może to sugerować, że inne czynniki (np. popularność innych debiutów, takich jak gambit królowej, który był tematem serialu) wpłynęły na dynamikę popularności partii włoskiej.

3. Porównanie z ogólną liczbą partii:


- Wcześniejsze analizy (np. wykres słupkowy z danymi `my_games_count`) pokazują, że ogólna liczba partii szachowych wzrosła znacząco po 2020 roku, co może być związane z premierą serialu *Gambit Królowej* i pandemią COVID-19, które zwiększyły zainteresowanie szachami online.
- Jednak w przypadku partii włoskiej tempo wzrostu zmalało po premierze, co kontrastuje z ogólnym trendem wzrostowym liczby wszystkich partii. Sugeruje to, że premiera serialu mogła bardziej promować inne debiuty (np. gambit królowej) kosztem partii włoskiej.

4. Istotność różnicy:

- Statystycznie istotna różnica w nachyleniach ($p = 0.0133$) potwierdza, że premiera serialu miała wpływ na dynamikę popularności partii włoskiej. Spadek tempa wzrostu może wskazywać, że gracze bardziej zainteresowali się debiutami promowanymi przez serial (np. gambit królowej), co zmniejszyło względną popularność partii włoskiej w porównaniu do okresu przed premierą.


Podsumowanie

Premiera serialu *Gambit Królowej* w październiku 2020 nie zwiększyła tempa wzrostu popularności partii włoskiej, a wręcz je spowolniła (spadek nachylenia z 21.878 do 11.912 partii miesięcznie). W kontekście ogólnej liczby partii szachowych, która wzrosła po 2020 roku, partia włoska stała się relatywnie mniej popularna, co może wskazywać na przesunięcie zainteresowania graczy w stronę innych debiutów, takich jak gambit królowej, promowany przez serial.



```
# CDF dla danych 'before' i 'after'
plot(ecdf(games_count_chrono_przed), col = "blue", main = "Dystrybuanta liczby partii",
      xlab = "Liczba partii", ylab = "Prawdopodobieństwo <= x")
lines(ecdf(games_count_chrono_po), col = "green")
legend("topleft", legend = c("Przed", "Po"), col = c("blue", "green"), lty=1)
```

Dystrybuanta liczby partii



- CDF pokazuje prawdopodobieństwo, że zmienna losowa przyjmie wartość mniejszą lub równą x.
- Można zobaczyć, czy po premierze rozkład przesunął się w prawo (więcej dużych wartości).
- Jeśli linia "po" jest poniżej "przed" dla danego x, oznacza to, że „po” jest generalnie większe.

Analiza nowego debiutu (otwarcie krowy)



The image shows a YouTube video player. On the left, a chessboard is displayed with a game in progress. The board is oriented with white at the bottom. White pieces are on squares b3, c3, d3, e3, f3, g3, h3, and a1. Black pieces are on squares a8, b8, c8, d8, e8, f8, g8, h8, and a7, b7, c7, d7, e7, f7, g7, h7. A yellow question mark icon is next to the white knight on b3. The video title is "I Invented a BRAND NEW Chess Opening: The Cow Opening!!!". The channel name is "Anna Cramling" with 1,04 mln subskrybentów. The video has 12 tys. likes, 1,04 mln subskrybentów, and 349 189 wyświetleń. The video was uploaded on 6 maj 2023. The video player interface includes a progress bar at 3:09 / 26:13, a volume icon, and a settings icon.

Pesto_rosso (2135) 2:59

0.3

8

7

6

5

4

3

2

1

a b c d e f g h

WM annacramling (2130) 3:09

3:54 / 26:13 • First Game (white pieces) >

I Invented a BRAND NEW Chess Opening: The Cow Opening!!!

Anna Cramling 1,04 mln subskrybentów

Subskrybujesz

12 tys.

Udostępnij

Pobierz

Podziękuj

349 189 wyświetleń 6 maj 2023 #annacramling #chess #opening

(Kod bardzo podobny do poprzedniego)

```

games_count_chrono <- rev(games_count_cow)

# Podział
games_count_chrono_przed <- games_count_chrono[1:124] # przed czerwiec 2023
games_count_chrono_po <- games_count_chrono[125:136] # czerwiec 2023 - kwiecień 2024

# Czas
time_przed <- 1:124
time_po <- 125:136

# Regresje
reg_przed <- lm(games_count_chrono_przed ~ time_przed)
summary(reg_przed)
reg_po <- lm(games_count_chrono_po ~ time_po)
summary(reg_po)

# Wyciągnięcie współczynników regresji (nachylenia)
beta1_przed <- coef(reg_przed)[2]
beta1_po <- coef(reg_po)[2]
delta_beta <- beta1_po - beta1_przed
cat("Różnica między współczynnikami regresji (po - przed):", delta_beta, "\n")

# Standardowe błędy nachyleń
se_beta1_przed <- summary(reg_przed)$coefficients[2, 2]
se_beta1_po <- summary(reg_po)$coefficients[2, 2]

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)

# Standardowy błąd różnicy
se_diff <- sqrt(se_beta1_przed^2 + se_beta1_po^2)|

# Wartość delta (np. o ile oczekujesz, że nachylenie jest większe po premierze)
delta <- 0 # Możesz ustawić np. delta = 50, jeśli chcesz sprawdzić konkretną różnicę

# Statystyka t dla różnicy nachyleń
t_stat <- (delta_beta - delta) / se_diff

# Stopnie swobody (przybliżenie)
df <- min(length(games_count_chrono_przed) - 2, length(games_count_chrono_po) - 2)

# Wartość p dla testu jednostronnego (H1: beta1_po < beta1_przed + delta)
# Poprawiony kierunek: lower.tail = TRUE, bo testujemy mniejsze nachylenie
p_value <- pt(t_stat, df, lower.tail = FALSE)

# Wyświetlenie wyników
cat("Statystyka t:", t_stat, "\n")
cat("Stopnie swobody:", df, "\n")
cat("Wartość p:", p_value, "\n")

plot(time, games_count_chrono, type = "l", xlab = "Miesiąc (1 = styczeń 2013, 136 = kwiecień 2024)",
      ylab = "Liczba gier z debiutem Otwarcie Krowy")
abline(reg_przed, col = "blue") # Linia regresji przed premierą
abline(reg_po, col = "red") # Linia regresji po premierze
abline(v = 94, lty = 2, col = "green") # Linia oznaczająca październik 2020 (data wydania serialu)
abline(v = 124, lty = 2, col = "darkgreen") # Linia oznaczająca październik 2020 (data debiutu krowy)
legend("topleft", legend = c("Linia regresji przed premierą", "Linia regresji po premierze",
                             "Data wydania serialu", "Data wymyślenia debiutu krowy"),
      col = c("blue", "red", "green", "darkgreen"), lty = c(1, 1, 2, 2))

```

```
Call:
lm(formula = games_count_chrono_przed ~ time_przed)

Residuals:
    Min       1Q   Median       3Q      Max
-0.3802 -0.2985 -0.2122 -0.1374  6.7775

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.099135   0.155125   0.639   0.524
time_przed   0.002285   0.002154   1.061   0.291

Residual standard error: 0.8585 on 122 degrees of freedom
Multiple R-squared:  0.00914,    Adjusted R-squared:  0.001018
F-statistic: 1.125 on 1 and 122 DF,  p-value: 0.2909
```

```
Call:
lm(formula = games_count_chrono_po ~ time_po)

Residuals:
    Min       1Q   Median       3Q      Max
-3.973 -2.065 -1.230  2.692  5.100

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -5.49883   36.55827  -0.150   0.883
time_po      0.07343    0.28004   0.262   0.798

Residual standard error: 3.349 on 10 degrees of freedom
Multiple R-squared:  0.006828,    Adjusted R-squared:  -0.09249
F-statistic: 0.06875 on 1 and 10 DF,  p-value: 0.7985

Różnica między współczynnikami regresji (po - przed): 0.07114176
Statystyka t: 0.254032
Stopnie swobody: 10
Wartość p: 0.4023089
```

Wyniki regresji liniowej

1. Regresja przed opublikowaniem debiutu (styczeń 2013 – maj 2023):

- Nachylenie (beta1_przed): 0.002285 – liczba partii rosła średnio o 0.002285% miesięcznie.
- Istotność: Wartość $p = 0.291$ wskazuje, że wzrost nie jest statystycznie istotny ($p > 0.05$).
- R-kwadrat: 0.00914 – model słabo dopasowuje się do danych (tylko 0.914% zmienności wyjaśnione przez czas).
- Interpretacja: W okresie przed opublikowaniem debiutu, jego popularność wykazywała minimalny i nieistotny wzrost, co może sugerować stabilny, ale nieznaczny trend w zainteresowaniu danym debiutem.

2. Regresja po opublikowaniu (maj 2023 – kwiecień 2024):

- Nachylenie (β_{1_po}): 0.07343 – liczba partii rosła średnio o 0.07343% miesięcznie.
- Istotność: Wartość $p = 0.798$ wskazuje, że wzrost nie jest statystycznie istotny ($p > 0.05$).
- R-kwadrat: 0.006828 – model bardzo słabo dopasowuje się do danych (tylko 0.6828% zmienności wyjaśnione przez czas).
- Interpretacja: Po opublikowaniu debiutu wzrost popularności partii jest minimalny i nieistotny statystycznie, co może wskazywać na brak wyraźnego wpływu publikacji na popularność tego debiutu lub większą zmienność w danych.

3. Porównanie nachyleń:

- Różnica ($\beta_{1_po} - \beta_{1_przed}$): 0.07114176 – nachylenie po premierze jest większe o 0.07114 w porównaniu do okresu przed premierą.
- Statystyka t: 0.254032
- Stopnie swobody: 10
- Wartość p: 0.4023089
- Interpretacja: Wartość $p = 0.4023$ (> 0.05) wskazuje, że różnica między nachyleniami nie jest statystycznie istotna. Nie ma wystarczających dowodów, aby stwierdzić, że opublikowanie debiutu miało istotny wpływ na zmianę tempa wzrostu popularności tego debiutu.

Wnioski w kontekście ogólnej liczby partii

1. Trend przed premierą:

- Liczba partii rosła w tempie 0.002285% miesięcznie, co jest bardzo niewielkie i nieistotne statystycznie. Niski R-kwadrat (0.00914) sugeruje, że czas nie jest głównym czynnikiem wpływającym na zmienność w tym okresie, co może odzwierciedlać stabilny, ale słaby poziom zainteresowania danym debiutem.

2. Trend po premierze:

- Po opublikowaniu debiutu tempo wzrostu wzrosło do 0.07343% miesięcznie, choć nadal pozostaje nieistotne statystycznie. Bardzo niski R-kwadrat (0.006828) wskazuje na słabe dopasowanie modelu i dużą zmienność, co może sugerować, że inne czynniki (np. popularność innych debiutów) miały większy wpływ po 2023 roku.

3. Porównanie z ogólną liczbą partii:

- Ogólna liczba partii szachowych wzrosła znacząco po 2020 roku, co może być związane z premierą serialu *Gambit Królowej* i pandemią COVID-19. Jednak w przypadku analizowanego debiutu tempo wzrostu pozostało minimalne i nieistotne, co kontrastuje z ogólnym trendem. Może to wskazywać, że premiera serialu nie wpłynęła znacząco na popularność tego konkretnego debiutu, a zainteresowanie przesunęło się na inne otwarcia, np. gambit królowej.


4. Istotność różnicy:

- Brak istotności statystycznej różnicy w nachyleniach ($p = 0.4023$) sugeruje, że opublikowanie debiutu nie miało wyraźnego wpływu na dynamikę popularności analizowanego debiutu. Tempo wzrostu pozostało niskie zarówno przed, jak i po premierze.

Podsumowanie

Opublikowanie debiutu Otwarcie Krowy w maju 2023 nie wpłynęło znacząco na tempo wzrostu popularności analizowanego debiutu, które pozostało minimalne (0.002285% przed i 0.07343% po) i nieistotne statystycznie. W kontekście ogólnego wzrostu liczby partii szachowych po 2023 roku, analizowany debiut nie odnotował proporcjonalnego wzrostu, co może sugerować, że zainteresowanie graczy skupiło się na innych otwarciach.

Porównanie ilości granych debiutów „Krowy” przed jej opublikowaniem i po opublikowaniu



Wnioski ogólne

1. Przed kluczowymi wydarzeniami medialnymi (2013–2020): Popularność debiutów takich jak gambit królowej, partia włoska oraz najnowsze debiuty była stosunkowo stabilna, z niewielkimi wahaniami w procentowym udziale gier. Brak wyraźnego trendu wzrostowego lub spadkowego wskazuje, że w tym okresie rozwój internetu i mediów społecznościowych nie miał jeszcze znaczącego wpływu na popularyzację tych debiutów.
2. Po kluczowych wydarzeniach medialnych (2020–2024): Po premierze serialu *Gambit Królowej* oraz wzroście znaczenia mediów społecznościowych i internetu odnotowano istotny wzrost popularności debiutów, w szczególności gambitu królowej. Procent gier z tym debiutem osiągnął szczyt w 2021 roku (ok. 8% w okolicach września 2021), po czym ustabilizował się na poziomie 2–6%, co nadal jest wyższym poziomem niż przed 2020 rokiem. W przypadku partii włoskiej i najnowszych debiutów zmiany były mniej wyraźne, ale również widoczne, co sugeruje, że wydarzenia medialne i rozwój mediów online miały istotny wpływ na dynamikę popularności debiutów.
3. Test hipotezy: Różnica między nachyleniami linii regresji ($\beta_{1_po} - \beta_{1_przed} \neq 0$) jest statystycznie istotna ($p < 0.05$), co prowadzi do odrzucenia hipotezy zerowej (H_0) na rzecz hipotezy alternatywnej (H_1). Wyniki wskazują, że kluczowe wydarzenia medialne, takie jak premiera serialu *Gambit Królowej*, oraz rozwój internetu i mediów społecznościowych miały istotny wpływ na popularyzację szachów.

V Listing komend generujących wyniki

```
# Statystyki opisowe
mean(my_games_count)          # Średnia arytmetyczna
sd(my_games_count)            # Odchylenie standardowe
(sd(my_games_count) / mean(my_games_count)) * 100 # Współczynnik
zmienności
quantile(my_games_count, probs = 0.25)          # Kwartyl 1
median(my_games_count)                          # Mediana
quantile(my_games_count, probs = 0.75)          # Kwartyl 3
mad(my_games_count, center = mean(my_games_count)) # Odchylenie
przeciętne
```

```

var(my_games_count)           # Wariancja
max(my_games_count)           # Maksymalna wartość
min(my_games_count)           # Minimalna wartość
max(my_games_count) - min(my_games_count) # Rozstęp
kurtosis(my_games_count)      # Kurtoza
skewness(my_games_count)      # Skośność

# Estymacja mody (trybu) z gęstości
dens <- density(my_games_count)
dens$x[which.max(dens$y)]      # Estymowana moda

# Testy statystyczne
shapiro.test(my_games_count)    # Test Shapiro-Wilka
shapiro.test(games_count_gambit)
shapiro.test(games_count_italian)

cor.test(my_games_count, games_count_gambit) # Test korelacji
Pearsona
cor.test(my_games_count, games_count_italian)

# Wizualizacja danych
ggplot(...) + geom_bar(...)    # Wykres słupkowy liczby partii
ggsave(...)                    # Zapis wykresu do pliku PNG

```

VI Opis użytych funkcji środowiska R

Funkcja	Opis działania	Pakiet
mean()	Oblicza średnią arytmetyczną zbioru danych.	base
sd()	Oblicza odchylenie standardowe.	base
quantile()	Oblicza kwartyle (lub inne percentyle) zbioru danych.	base
median()	Oblicza medianę, czyli środkową wartość zbioru.	base
mad(center = mean())	Oblicza odchylenie przeciętne względem średniej.	base

Funkcja	Opis działania	Pakiet
<code>var()</code>	Oblicza wariancję – miarę rozproszenia danych.	base
<code>max()</code> / <code>min()</code>	Znajduje wartość maksymalną / minimalną.	base
<code>kurtosis()</code>	Oblicza kurtozę – spiczastość rozkładu.	moments
<code>skewness()</code>	Oblicza skośność – asymetrię rozkładu.	moments
<code>density()</code>	Szacuje funkcję gęstości rozkładu – używana do estymacji mody.	base
<code>shapiro.test()</code>	Testuje normalność rozkładu danych (Shapiro-Wilk).	stats
<code>cor.test()</code>	Testuje korelację (domyślnie Pearson, można zmienić metodę).	stats
<code>ggplot()</code> / <code>geom_bar()</code>	Tworzy wykresy (słupkowe, liniowe itd.)	ggplot2
<code>labs()</code> , <code>scale_fill_manual()</code>	Dodaje opisy, legendy do wykresu	ggplot2
<code>scale_x_continuous()</code> , <code>theme()</code>	Ustawienia osi, czcionki, rozmiarów	ggplot2
<code>unit_format(unit = "M", scale = 1e-6)</code>	Formatuje osie liczbowo, np. w milionach	scales
<code>ggsave()</code>	Zapisuje wykres do pliku graficznego	ggplot2
<code>pander()</code>	Formatuje wyniki testów statystycznych w stylu tabeli (Markdown)	pander