



**POLITECHNIKA
RZESZOWSKA**
im. IGNACEGO ŁUKASIEWICZA

WYDZIAŁ MATEMATYKI I FIZYKI STOSOWANEJ

Projekt:

Wpływ internetu i mediów społecznościowych na popularyzację szachów:

Szeregi czasowe

Rafał Bazan

Rzeszów 2025

Spis treści

I Opis użytych danych.....	3
II Omówienie danych.....	6
Pierwsze dane	6
Drugie dane	6
Przygotowanie danych do analizy	8
Zamiana na szereg czasowy i wizualizacja	8
Wstępne obserwacje dotyczące danych szachowych	11
Monthplot	12
Boxplot	14
seasonplot	16
Lag.plot	18
acf	20
pacf	21
Dekompozycje	23
Eliminacja trendu i sezonowości	31
Metody estymacji	35
Arima	36
Optymalne modele	37
Sprawdzenie szumu białego	39

I Opis użytych danych

Źródło danych: Dane wykorzystane w prezentacji pochodzą z bazy danych platformy szachowej Lichess, dostępnej pod adresem <https://database.lichess.org>. Są to publicznie dostępne zbiory danych zawierające informacje o partiach szachowych rozegranych na tej platformie. Dane pobierane były w formacie PGN (Portable Game Notation) oraz w formacie .zst.torrent, które obejmują zarówno metadane partii, jak i pełne zapisy ruchów.

Scrapowanie danych przeprowadzono przy użyciu języka R, korzystając z bibliotek takich jak rvest, stringi, dplyr czy ggplot2, a dane pobierano z konkretnej tabeli na stronie Lichess (ścieżka XPath: /html/body/div/div[2]/div[2]/section[1]/table).

Dane zostały zredukowane do 0,001% ich pierwotnej wartości ze względu na dużą ilość.

Czego dotyczą dane: Dane dotyczą partii szachowych rozegranych na platformie Lichess od 2013 roku do kwietnia 2024 roku. Obejmują one:

- **Liczbę rozegranych partii:** Informacje o liczbie gier w danym miesiącu.
- **Metadane partii:** Informacje takie jak data, rok, miesiąc, rodzaj debiutu (np. [Opening „Sicilian Defense: Old Sicilian”]), rankingi ELO graczy (np. WhiteElo, BlackElo), oraz sekwencje ruchów w notacji algebraicznej.

Sample

```
[Event "Rated Bullet tournament https://lichess.org/tournament/yc1ww20x"]
[Site "https://lichess.org/PpwPOZMq"]
[Date "2017.04.01"]
[Round "-"]
[White "Abbot"]
[Black "Costello"]
[Result "0-1"]
[UTCDate "2017.04.01"]
[UTCTime "11:32:01"]
[WhiteElo "2100"]
[BlackElo "2000"]
[WhiteRatingDiff "-4"]
[BlackRatingDiff "+1"]
[WhiteTitle "FM"]
[ECO "B30"]
[Opening "Sicilian Defense: Old Sicilian"]
[TimeControl "300+0"]
[Termination "Time forfeit"]

1. e4 { [%eval 0.17] [%clk 0:00:30] } 1... c5 { [%eval 0.19] [%clk 0:00:30] }
2. Nf3 { [%eval 0.25] [%clk 0:00:29] } 2... Nc6 { [%eval 0.33] [%clk 0:00:30] }
3. Bc4 { [%eval -0.13] [%clk 0:00:28] } 3... e6 { [%eval -0.04] [%clk 0:00:30] }
4. c3 { [%eval -0.4] [%clk 0:00:27] } 4... b5? { [%eval 1.18] [%clk 0:00:30] }
5. Bb3?! { [%eval 0.21] [%clk 0:00:26] } 5... c4 { [%eval 0.32] [%clk 0:00:29] }
6. Bc2 { [%eval 0.2] [%clk 0:00:25] } 6... a5 { [%eval 0.6] [%clk 0:00:29] }
7. d4 { [%eval 0.29] [%clk 0:00:23] } 7... cxd3 { [%eval 0.6] [%clk 0:00:27] }
8. Qxd3 { [%eval 0.12] [%clk 0:00:22] } 8... Nf6 { [%eval 0.52] [%clk 0:00:26] }
9. e5 { [%eval 0.39] [%clk 0:00:21] } 9... Nd5 { [%eval 0.45] [%clk 0:00:25] }
10. Bg5?! { [%eval -0.44] [%clk 0:00:18] } 10... Qc7 { [%eval -0.12] [%clk 0:00:24] }
11. Nbd2?? { [%eval -3.15] [%clk 0:00:14] } 11... h6 { [%eval -2.99] [%clk 0:00:23] }
12. Bh4 { [%eval -3.0] [%clk 0:00:11] } 12... Ba6? { [%eval -0.12] [%clk 0:00:20] }
13. b3?? { [%eval -4.14] [%clk 0:00:02] } 13... Nf4? { [%eval -2.73] [%clk 0:00:19] }
```

Rysunek 1

Filter	
▲	V1
1	[Event "Rated Classical game"]
2	[Site "https://lichess.org/j1dkb5dw"]
3	[White "BFG9k"]
4	[Black "mamalak"]
5	[Result "1-0"]
6	[UTCDate "2012.12.31"]
7	[UTCTime "23:01:03"]
8	[WhiteElo "1639"]
9	[BlackElo "1403"]
10	[WhiteRatingDiff "+5"]
11	[BlackRatingDiff "-8"]
12	[ECO "C00"]
13	[Opening "French Defense: Normal Variation"]
14	[TimeControl "600+8"]
15	[Termination "Normal"]
16	1. e4 e6 2. d4 b6 3. a3 Bb7 4. Nc3 Nh6 5. Bxh6 gxh6 6. Be2 ...
17	[Event "Rated Classical game"]
Showing 1 to 18 of 2,174 entries, 1 total columns	

Uzasadnienie wyboru danych:


- **Lichess jako źródło:** Lichess jest jedną z najpopularniejszych platform szachowych online, oferującą ogromną bazę danych partii, co czyni ją reprezentatywnym źródłem do analizy szeregów czasowych w szachach cyfrowych. Publiczna dostępność i duża liczba partii (np. 91–98 milionów miesięcznie w 2024 roku) zapewniają solidną podstawę do badań.
- Dane te umożliwiły wyciągnięcie wniosków dotyczących wzrostu popularności szachów oraz wpływu pandemii COVID i serialu "Gambit królowej" na zaangażowanie graczy.

II Omówienie danych

Pierwsze dane

Pierwsze dane odnoszą się do pełnej liczby partii szachowych rozegranych na platformie Lichess w każdym miesiącu w okresie od stycznia 2013 roku do kwietnia 2024 roku. Oznacza to, że obejmują one wszystkie partie szachowe zarejestrowane w tym czasie, niezależnie od rodzaju debiutu, kategorii gry (np. klasyczne, błyskawiczne) czy rankingów graczy. Liczba partii w każdym miesiącu odzwierciedla ogólny poziom aktywności użytkowników platformy w danym okresie.

Zgodnie z wymaganiami, dane te pokazują widoczny trend wzrostu popularności szachów w czasie, co może być związane z rosnącym wpływem internetu, mediów społecznościowych oraz wydarzeń kulturowych, takich jak premiera serialu „Gambit królowej” w 2020 roku.




Drugie dane

Drugie dane odnoszą się do zredukowanej liczby partii szachowych, stanowiących 0,001% pierwotnej wartości, które rozpoczęły się debiutem „Gambit królowej” (ang. Queen's Gambit), w każdym miesiącu od stycznia 2013 roku do kwietnia 2024 roku. Redukcja

danych została przeprowadzona ze względu na ogromną ilość partii dostępnych w bazie Lichess (np. dziesiątki milionów gier miesięcznie w 2024 roku), co umożliwia skoncentrowanie analizy na popularności konkretnego debiutu szachowego. Debiut „Gambit królowej” został wybrany jako obiekt badania w kontekście wpływu serialu o tej samej nazwie na zainteresowanie szachami.

Zgodnie z wymaganiami, dane te pokazują widoczną sezonowość, a także wyraźny skok popularności debiutu „Gambit królowej” po premierze serialu w październiku 2020 roku, co sugeruje wpływ mediów na preferencje graczy.



Oba zestawy danych stanowią szeregi czasowe o częstotliwości miesięcznej, co pozwala na analizę trendów długoterminowych, sezonowości oraz wpływu konkretnych wydarzeń na popularność szachów i zachowanie graczy na platformie Lichess. Analiza tych danych została przeprowadzona w języku R w środowisku RStudio, co umożliwia szczegółowe badanie statystyczne i wizualizację wyników.

Przygotowanie danych do analizy

Dane zostały przygotowane w ramach odrębnego projektu, obejmującego zbieranie i oczyszczanie danych z pełnego zbioru Lichess o wielkości 15 TB, zawierającego około 7 miliardów partii szachowych. Ze względu na ich złożony charakter, szczegóły wczytywania i przetwarzania nie są tutaj przedstawiane. Dane są odpowiednio dostosowane do analizy szeregów czasowych w RStudio.

Description: df [136 x 2]

year <chr>	count <dbl>
2024	91377787
2024	95804114
2024	91567975
2024	98994760
2023	96909211
2023	92389636
2023	94922297
2023	93218629
2023	96118124
2023	95300285

Zamiana na szereg czasowy i wizualizacja

Aby używać funkcji dotyczących szeregów czasowych musiałem najpierw odczytać moje dane jako szereg czasowy. Najpierw zająłem się szeregiem łącznej liczby partii. W tym celu użyłem funkcji poniżej


```
ts_my_games_count = ts(rev(my_games_count), start = c(2013,1), end=c(2024,4),frequency = 12)

plot(1:length(rev(my_games_count)),
     ts_my_games_count / 1e6,
     type = "l",
     xlab = "Rok",
     ylab = "Liczba zagranych partii na stronie lichess",
     xaxt = "n",
     yaxt = "n")

y_values <- axTicks(2)
y_labels <- paste0(y_values, "M")
axis(2, at = y_values, labels = y_labels, las = 1)

axis(1, at = tick_indices, labels = tick_labels, las = 2)
```

oraz zwizualizowałem funkcją plot()




Następnie zająłem się szeregiem partii gambit królowej

```
ts_games_count_gambit = ts(rev(games_count_gambit), start =c(2013,1), end=c(2024,4),frequency = 12)

plot(1:length(games_count_gambit),
     ts_games_count_gambit,
     type = "l",
     xlab = "Rok",
     ylab = "Liczba zagranych partii z debiutem Gambit Królowej po redukcji danych",
     xaxt = "n",
     yaxt = "n")

y_values <- axTicks(2)
y_labels <- paste0(y_values)
axis(2, at = y_values, labels = y_labels, las = 1)

axis(1, at = tick_indices, labels = tick_labels, las = 2)
```




Następnie w celu lepszego zaobserwowania sezonowości zmniejszyłem przedział czasowy

```
window_ts_my_games_count = window(ts_my_games_count, start=c(2013,1), end=c(2020,1))
plot(1:length(window_ts_my_games_count),
     window_ts_my_games_count / 1e6,
     type = "l",
     xlab = "Rok",
     ylab = "Liczba zagranych partii na stronie lichess",
     xaxt = "n",
     yaxt = "n")

y_values <- axTicks(2)
y_labels <- paste0(y_values, "M")
axis(2, at = y_values, labels = y_labels, las = 1)

axis(1, at = tick_indices, labels = tick_labels, las = 2)
```



Wstępne obserwacje dotyczące danych szachowych

Na podstawie analizy wykresów związanych z projektem o szachach, można wyciągnąć następujące wstępne wnioski:

- Wzrost popularności szachów:

Dane wskazują na stały wzrost liczby rozegranych partii szachowych na platformie Lichess w latach 2013–2024. Ten trend sugeruje coraz większe zainteresowanie szachami, co może wynikać z rozwoju platform online, wpływu mediów społecznościowych oraz wydarzeń kulturowych.

- Skok po 2020 roku i wpływ pandemii:

W 2020 roku obserwuje się znaczący wzrost liczby partii, który pokrywa się z początkiem pandemii COVID-19 oraz premierą serialu „Gambit królowej”. Pandemia mogła zwiększyć zainteresowanie szachami jako formą rozrywki w czasie lockdownów, a serial dodatkowo wzmocnił ten efekt, szczególnie w kontekście popularności debiutu „Gambit królowej”.


- Sezonowe wahania:

Po 2020 roku dane pokazują większe fluktuacje w aktywności graczy. Może to wskazywać na sezonowość w liczbie rozgrywanych partii, a regularne wzrosty w styczniu mogą być związane z organizacją międzynarodowych zawodów szachowych, które zwiększają popularność szachów w tym okresie. Zmiany preferencji dotyczących debiutów mogą być również powiązane z dostosowaniem się graczy do nowych realiów po pandemii.


Te obserwacje mogą stanowić punkt wyjścia do dalszej analizy wpływu pandemii, wydarzeń zewnętrznych i kalendarza zawodów na popularność szachów oraz zachowania graczy na platformie Lichess.

Monthplot

Funkcja monthplot




Wartości dużo się nie różnią między miesiącami, Widać dużą sezonowość. Średnie wartości miesięczne istotnie się nie różnią




Wartości dużo się nie różnią między miesiącami, Widać dużą sezonowość. Średnie wartości miesięczne istotnie się nie różnią.

Boxplot

Funkcja Boxplot







Jak widać wartości w obu danych nie różnią się między miesiącami. Oznacza to, że wartości w badanym szeregu czasowym są w miarę stabilne i nie różnią się znacząco w zależności od miesiąca.

seasonplot

Funkcja seasonplot







Jak widać oba wykresy mają trend rosnący z podobnym tempem.

Lag.plot

Funkcja lag.plot()







Korelacja jest duża dla każdego kroku w przypadku obu danych.

acf

Funkcja `acf()`







W pierwszym przypadku, jak i drugim Trend jest wzrostowy

pacf

Funkcja `pacf()`

Series ts_my_games_count






Jak widać w drugim pacf w $X=13$ jest szpilka wystająca poza poziom istotności.

Dekompozycje


Dekopozycja addytywna

Funkcja `plot(decompose([Dane],type = "additive"))`

Decomposition of additive time series



Decomposition of additive time series




Dekompozycja addytywna odnosi się do metody dzielenia szeregu czasowego na składowe addytywne, tj. trend, sezonowość i resztki. Metoda ta ma na celu identyfikację i izolację tych składników, aby lepiej zrozumieć strukturę danych i przewidywać ich przyszłe zachowanie.


Dekompozycja multiplikatywna

Funkcja `plot(decompose([Dane],type = "multiplicative"))`

Decomposition of multiplicative time series



Decomposition of multiplicative time series





Dekompozycja z użyciem ruchomej średniej

Dekompozycja za pomocą ruchomej średniej jest stosunkowo prosta w implementacji i może być przydatna w wygładzaniu danych oraz identyfikacji ogólnego trendu. Jednakże, może być ograniczona w przypadku analizy sezonowości i nieliniowych wzorców w danych.

```
ts_my_games_countAPma3 <- stats::filter(ts_my_games_count, sides = 2, filter = rep(1/3, 3))
ts_my_games_countAPma7 <- stats::filter(ts_my_games_count, sides = 2, filter = rep(1/7, 7))
ts_my_games_countAPma11 <- stats::filter(ts_my_games_count, sides = 2, filter = rep(1/11, 11))
plot(ts_my_games_count)
lines(ts_my_games_countAPma3, col = "red")
lines(ts_my_games_countAPma7, col = "purple")
lines(ts_my_games_countAPma11, col = "green")

ts_games_count_gambitAPma3 <- stats::filter(ts_games_count_gambit, sides = 2, filter = rep(1/3, 3))
ts_games_count_gambitAPma7 <- stats::filter(ts_games_count_gambit, sides = 2, filter = rep(1/7, 7))
ts_games_count_gambitAPma11 <- stats::filter(ts_games_count_gambit, sides = 2, filter = rep(1/11, 11))
plot(ts_games_count_gambit)
lines(ts_games_count_gambitAPma3, col = "red")
lines(ts_games_count_gambitAPma7, col = "purple")
lines(ts_games_count_gambitAPma11, col = "green")
```







Dekompozycja z użyciem ruchomej średniej bardzo silnie odwzorowuje rzeczywiste dane.

Dekompozycja na podstawie modelu regresji

```
ts_my_games_countAPT <- tslm(ts_my_games_count ~ trend) # tworzenie modelu uwzględniającego trend
summary(ts_my_games_countAPT)
ts_my_games_countAPTS <- tslm(ts_my_games_count ~ trend + season) #tworzenie modelu uwzględniającego trend i
sezonowość
ts_my_games_count_cox <- tslm(ts_my_games_count ~ trend + season, lambda = "auto") #tworzenie modelu uwzględniającego
trend i sezonowość
plot(ts_my_games_count)
lines(fitted(ts_my_games_countAPT), col = "red", lty = 2) #rysowanie wartości na podstawie modelu
lines(fitted(ts_my_games_countAPTS), col = "blue", lty = 2)
lines(fitted(ts_my_games_count_cox), col = "green", lty = 2)
legend("topleft", legend = c("Trend", "Trend + Sezonowość", "Box-cox"),
      col = c("red", "blue", "green"), pch = 16)

ts_games_count_gambitAPT <- tslm(ts_games_count_gambit ~ trend) # tworzenie modelu uwzględniającego trend
#str(APT) #;)
summary(ts_games_count_gambitAPT)
ts_games_count_gambitAPTS <- tslm(ts_games_count_gambit ~ trend + season) #tworzenie modelu uwzględniającego trend i
sezonowość
ts_games_count_gambit_cox <- tslm(ts_games_count_gambit ~ trend + season, lambda = "auto")
plot(ts_games_count_gambit)
lines(fitted(ts_games_count_gambitAPT), col = "red", lty = 2) #rysowanie wartości na podstawie modelu
lines(fitted(ts_games_count_gambitAPTS), col = "blue", lty = 2)
lines(fitted(ts_games_count_gambit_cox), col = "green", lty = 2)
legend("topleft", legend = c("Trend", "Trend + Sezonowość", "Box-cox"),
      col = c("red", "blue", "green"), pch = 16)
```







Eliminacja trendu i sezonowości

Eliminacja sezonowości z szeregu wszystkich partii i partii gambit królowej

```
ts_my_games_countAP <- ts_my_games_count
ts_my_games_countAPD <- decompose(ts_my_games_countAP, type = "multiplicative")
ts_my_games_countAPSA <- seasadj(ts_my_games_countAPD)
plot(ts_my_games_countAP)
lines(ts_my_games_countAPSA, col = "blue", lty = 1)
legend("topleft", legend=c("Partie", "Dane odsezonowane"), col=c("black", "blue"), lty=c(1,2))

ts_games_count_gambitAP <- ts_games_count_gambit
ts_games_count_gambitAPD <- decompose(ts_games_count_gambitAP, type = "multiplicative")
ts_games_count_gambitAPSA <- seasadj(ts_games_count_gambitAPD)
plot(ts_games_count_gambitAP)
lines(ts_games_count_gambitAPSA, col = "blue", lty = 1)
legend("topleft", legend=c("Partie", "Dane odsezonowane"), col=c("black", "blue"), lty=c(1,2))
```









Eliminacja trendu z szeregu wszystkich partii i partii gambit królowej

```
tsdisplay(ts_my_games_count)
ts_my_games_countDiff <- diff(ts_my_games_count)
tsdisplay(ts_my_games_countDiff)
ts_my_games_countDiff2 <- diff(ts_my_games_count, lag = 12)
tsdisplay(ts_my_games_countDiff2)

tsdisplay(ts_games_count_gambit)
ts_games_count_gambitDiff <- diff(ts_games_count_gambit)
tsdisplay(ts_games_count_gambitDiff)
ts_games_count_gambitDiff2 <- diff(ts_games_count_gambit, lag = 12)
tsdisplay(ts_games_count_gambitDiff2)
```

ts_my_games_countDiff2





Szereg pracownicy nie jest realizacją szumu białego ponieważ posiada strzałki odstające poza poziom istotności. Warto brania pod uwagę rzędy modeli $AR(p)$ i $MA(q)$ to 12 dla p oraz 1 dla q .

Metody estymacji

Dla szeregu wszystkich partii i partii gambit królowej

```
ts_my_games_countDiff2.yw = ar(ts_my_games_countDiff2, aic=FALSE, order.max = 10, c("yule-walker"))
print(ts_my_games_countDiff2.yw)
ts_my_games_countDiff2.mle = ar(ts_my_games_countDiff2, aic=FALSE, order.max = 7, c("mle"))
print(ts_my_games_countDiff2.mle)
ts_my_games_countDiff2.aic = ar(ts_my_games_countDiff2, aic=TRUE)
print(ts_my_games_countDiff2.aic)

ts_games_count_gambitDiff2.yw = ar(ts_games_count_gambitDiff2, aic=FALSE, order.max = 10, c("yule-walker"))
print(ts_games_count_gambitDiff2.yw)
ts_games_count_gambitDiff2.mle = ar(ts_games_count_gambitDiff2, aic=FALSE, order.max = 7, c("mle"))
print(ts_games_count_gambitDiff2.mle)
ts_games_count_gambitDiff2.aic = ar(ts_games_count_gambitDiff2, aic=TRUE)
print(ts_games_count_gambitDiff2.aic)
```

```

Call:
ar(x = ts_my_games_countDiff2, aic = FALSE, order.max = 10, method = c("yule-walker"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10
 1.2037 -0.3589  0.1297 -0.1452  0.1041  0.0029  0.1513 -0.0901  0.0443 -0.1369

Order selected 10  sigma^2 estimated as  1.491e+13

Call:
ar(x = ts_my_games_countDiff2, aic = FALSE, order.max = 7, method = c("mle"))

Coefficients:
      1      2      3      4      5      6      7
 1.3146 -0.4116  0.0284 -0.0343 -0.0499  0.2119 -0.1101

Order selected 7  sigma^2 estimated as  1.12e+13

Call:
ar(x = ts_my_games_countDiff2, aic = TRUE)

Coefficients:
      1      2
 1.2380 -0.3124

Order selected 2  sigma^2 estimated as  1.537e+13

Call:
ar(x = ts_games_count_gambitDiff2, aic = FALSE, order.max = 10, method = c("yule-walker"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10
 0.9843 -0.0862  0.0520 -0.0676 -0.1961  0.3160  0.0569 -0.0210 -0.1122 -0.0368

Order selected 10  sigma^2 estimated as  41265

Call:
ar(x = ts_games_count_gambitDiff2, aic = FALSE, order.max = 7, method = c("mle"))

Coefficients:
      1      2      3      4      5      6      7
 1.0233 -0.0990  0.0256 -0.0872 -0.2003  0.3638 -0.0852

Order selected 7  sigma^2 estimated as  33278

Call:
ar(x = ts_games_count_gambitDiff2, aic = TRUE)

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
 1.0301 -0.1206  0.0075 -0.0135 -0.1599  0.2976 -0.0583  0.0689 -0.1240  0.0759 -0.0514 -0.3529
      13      14
 0.4358 -0.1421

Order selected 14  sigma^2 estimated as  37429

```

Każda metoda daje inny wynik jednak dobór automatyczny jest bliższy metodzie Yule-Walkera. Automatyczna metoda dobrała rząd 2 natomiast w poprzednich ręcznie nastawiłem 14.

Arima

Arima dla szeregu wszystkich partii i partii gambit królowej

```
ts_my_games_countDiff2.arma = Arima(ts_my_games_countDiff2,order = c(2,0,0))
ts_my_games_countDiff2.arma

ts_games_count_gambitDiff2.arma = Arima(ts_games_count_gambitDiff2,order = c(14,0,1))
ts_games_count_gambitDiff2.arma
...
```

```
Series: ts_my_games_countDiff2
ARIMA(2,0,0) with non-zero mean
```

Coefficients:

	ar1	ar2	mean
	1.2975	-0.3572	7445973
s.e.	0.0832	0.0844	5096006

```
sigma^2 = 1.183e+13: log likelihood = -2042.1
AIC=4092.2 AICc=4092.53 BIC=4103.48
```

```
Series: ts_games_count_gambitDiff2
ARIMA(14,0,1) with non-zero mean
```

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ar6	ar7	ar8	ar9	ar10	ar11	ar12
	0.3090	0.7181	-0.0459	-0.1304	-0.1321	0.1799	0.2865	-0.0431	-0.2088	0.0846	0.0375	-0.4979
s.e.	0.2013	0.1977	0.1038	0.1047	0.1021	0.1027	0.1063	0.1023	0.1024	0.1037	0.1072	0.1013

	ar13	ar14	ma1	mean
	0.2258	0.0863	0.7935	263.2158
s.e.	0.1620	0.1494	0.1736	181.3231

```
sigma^2 = 24894: log likelihood = -798.78
AIC=1631.55 AICc=1637.33 BIC=1679.5
```

Optymalne modele

Auto.arma dla szeregu wszystkich partii i partii gambit królowej

```
ts_my_games_countDiff2.auto_aic = auto.arma(ts_my_games_countDiff2, ic = "aic")
ts_my_games_countDiff2.auto_aic
ts_my_games_countDiff2.auto_aaic = auto.arma(ts_my_games_countDiff2, ic = "aicc")
ts_my_games_countDiff2.auto_aaic
ts_my_games_countDiff2.auto_bic = auto.arma(ts_my_games_countDiff2, ic = "bic")
ts_my_games_countDiff2.auto_bic

ts_games_count_gambitDiff2.auto_aic = auto.arma(ts_games_count_gambitDiff2, ic = "aic")
ts_games_count_gambitDiff2.auto_aic
ts_games_count_gambitDiff2.auto_aaic = auto.arma(ts_games_count_gambitDiff2, ic = "aicc")
ts_games_count_gambitDiff2.auto_aaic
ts_games_count_gambitDiff2.auto_bic = auto.arma(ts_games_count_gambitDiff2, ic = "bic")
ts_games_count_gambitDiff2.auto_bic
...
```

```
Series: ts_my_games_countDiff2
ARIMA(1,1,0)(0,0,1)[12]
```

Coefficients:

	ar1	ma1
	0.2578	-0.4489
s.e.	0.0891	0.0853

```
sigma^2 = 1.008e+13: log likelihood = -2016.29
AIC=4038.58 AICc=4038.78 BIC=4047.01
```

Series: ts_my_games_countDiff2
ARIMA(1,1,0)(0,0,1)[12]

Coefficients:

	ar1	sma1
	0.2578	-0.4489
s.e.	0.0891	0.0853

sigma^2 = 1.008e+13: log likelihood = -2016.29
AIC=4038.58 AICc=4038.78 BIC=4047.01
Series: ts_my_games_countDiff2
ARIMA(1,1,0)(0,0,1)[12]

Coefficients:

	ar1	sma1
	0.2578	-0.4489
s.e.	0.0891	0.0853

sigma^2 = 1.008e+13: log likelihood = -2016.29
AIC=4038.58 AICc=4038.78 BIC=4047.01
Series: ts_games_count_gambitDiff2
ARIMA(2,1,2)(1,0,1)[12]

Coefficients:

	ar1	ar2	ma1	ma2	sar1	sma1
	1.0721	-0.9135	-0.9609	0.9324	-0.3331	-0.3111
s.e.	0.0688	0.0625	0.0690	0.0525	0.1567	0.1692

sigma^2 = 23678: log likelihood = -794.41
AIC=1602.83 AICc=1603.8 BIC=1622.51

```
-----  
Series: ts_games_count_gambitDiff2  
ARIMA(2,1,2)(1,0,1)[12]
```

Coefficients:

	ar1	ar2	ma1	ma2	sar1	sma1
	1.0721	-0.9135	-0.9609	0.9324	-0.3331	-0.3111
s.e.	0.0688	0.0625	0.0690	0.0525	0.1567	0.1692

```
sigma^2 = 23678: log likelihood = -794.41  
AIC=1602.83 AICc=1603.8 BIC=1622.51  
Series: ts_games_count_gambitDiff2  
ARIMA(0,1,0)(0,0,1)[12]
```

Coefficients:

	sma1
	-0.6145
s.e.	0.0754

```
sigma^2 = 26030: log likelihood = -802.14  
AIC=1608.29 AICc=1608.39 BIC=1613.91
```

Najlepszym modelem jest ARIMA(1,1,0)(0,0,1)[12] dla szeregu wszystkich partii


Oraz ARIMA(2,1,2)(1,0,1)[12] dla szeregu partii gambit królowej

Sprawdzenie szumu białego


Do sprawdzenia użyłem funkcji `tsdiag()` oraz `acf()`

Dla wszystkich partii


Standardized Residuals




ACF of Residuals



p values for Ljung-Box statistic




Series ts_my_games_countDiff2.auto_aic\$residuals




Dla partii gambit królowej


Standardized Residuals




ACF of Residuals



p values for Ljung-Box statistic






Szereg jest realizacją szumu białego ponieważ wartości p są większe niż 0,5.

Przewidywania naiwne


Dla wszystkich partii na najbliższe 4 lata

```
ts_my_games_count.meanf = meanf(ts_my_games_count, h = 48)
plot(ts_my_games_count.meanf)
ts_my_games_count.naive = naive(ts_my_games_count, h = 48)
plot(ts_my_games_count.naive)
ts_my_games_count.snaive = snaive(ts_my_games_count, h = 48)
plot(ts_my_games_count.snaive)
ts_my_games_count.rwf = rwf(ts_my_games_count, h = 48, drift = TRUE)
plot(ts_my_games_count.rwf)
```


Forecasts from Mean




Forecasts from Naive method



Forecasts from Seasonal naive method




Forecasts from Random walk with drift




Dla partii gambit królowej na najbliższy rok

```
ts_games_count_gambit.meanf = meanf(ts_games_count_gambit, h = 12)
plot(ts_games_count_gambit.meanf)
ts_games_count_gambit.naive = naive(ts_games_count_gambit, h = 12)
plot(ts_games_count_gambit.naive)
ts_games_count_gambit.snaive = snaive(ts_games_count_gambit, h = 12)
plot(ts_games_count_gambit.snaive)
ts_games_count_gambit.rwf = rwf(ts_games_count_gambit, h = 12, drift = TRUE)
plot(ts_games_count_gambit.rwf)
```


Forecasts from Mean




Forecasts from Naive method



Forecasts from Seasonal naive method




Forecasts from Random walk with drift



Przewidywania nie naiwne


Dla wszystkich partii na najbliższe 4 lata

Forecasts from ARIMA(1,1,0)(0,0,1)[12]



Dla partii gambit królowej na najbliższe 4 lata

Forecasts from ARIMA(2,1,2)(1,0,1)[12]



Wnioski

Analiza danych szachowych z platformy Lichess (2013–2024) wykazała stały wzrost popularności szachów, który przyspieszył w 2020 roku w wyniku pandemii COVID-19 i premiery serialu „Gambit królowej”. Skok liczby partii w tym okresie wskazuje, że szachy stały się popularną formą rozrywki w czasie lockdownów, a medialne zainteresowanie wpłynęło na preferencje graczy, szczególnie w kontekście debiutu „Gambit królowej”. Internet i media społecznościowe, w tym streaming, odegrały kluczową rolę w tym procesie, czyniąc szachy dostępnymi i atrakcyjnymi dla nowych grup odbiorców.

Sezonowe wahania i strategiczne wzrosty w styczniu, prawdopodobnie związane z międzynarodowymi turniejami, podkreślają wpływ kalendarza wydarzeń na dynamikę gry. Rozwój technologii dodatkowo wspiera ten trend, eliminując bariery dostępu i przekształcając szachy w globalne zjawisko kulturowe.

Zastosowanie dekompozycji (addytywnej i multiplikatywnej) oraz eliminacji trendu i sezonowości umożliwiło uzyskanie stacjonarnych szeregów czasowych, co pozwoliło na skuteczne modelowanie ARIMA. Najlepsze modele – ARIMA(1,1,0)(0,0,1)[12] dla

wszystkich partii i $ARIMA(2,1,2)(1,0,1)[12]$ dla „Gambitu królowej” – dobrze dopasowują się do danych (reszty jako szum biały) i prognozują dalszy wzrost popularności szachów.